

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



Khóa Luận Tốt Nghiệp Đại Học

MÔ HÌNH DỰ ĐOÁN CHO DỮ LIỆU CHĂM SÓC SỨC KHỎE

KHOA TOÁN-TIN HỌC
NGÀNH TOÁN HỌC
CHUYÊN NGÀNH KHOA HỌC DỮ LIỆU
KHÓA 2022

Sinh viên thực hiện | MSSV

Lê Vũ Uyển Nhi | 22110145

Giảng viên hướng dẫn: TS. Tô Đức Khánh

Tp. Hồ Chí Minh, 20/07, 2026

LỜI CAM ĐOAN

[lorem ispsun...]

Tp. Hồ Chí Minh, ngày tháng năm 2026

Lê Vũ Uyên Nhi

LỜI CẢM ƠN

[lorem ispsun...]

Tp. Hồ Chí Minh, ngày tháng năm 2026

Lê Vũ Uyên Nhi

TÓM TẮT NỘI DUNG

[lorem ipsum...]

Mục Lục

Lời Cam Đoan	i
Lời Cảm Ơn	ii
Tóm Tắt Nội Dung	iii
Mục Lục	iv
Danh Mục Các Hình và Biểu Đồ	viii
Danh Mục Bảng	x
Danh Mục Các Từ Viết Tắt	xii
Danh Sách Thuật Ngữ	xiii
Thông Tin Khóa Luận (Tiếng Việt)	xv
Thesis Information (English)	xvi
1 Giới thiệu	1

1.1	Lý do chọn đề tài	1
1.2	Mục tiêu nghiên cứu	2
1.3	Đối tượng và phạm vi nghiên cứu	3
1.3.1	Breast Cancer Gene Expression Dataset (GSE45827 - CuMiDa)	3
1.3.2	Diabetes Health Indicators Dataset (BRFSS 2015 - CDC)	3
1.3.3	Phạm vi nghiên cứu	4
1.3.4	Nội dung thực hiện	4
1.3.5	Bố cục khóa luận	5
2	Cơ sở lý thuyết	7
2.1	Tổng quan về ứng dụng học máy trong việc dự đoán dữ liệu chăm sóc sức khỏe	7
2.2	Đặc tính của dữ liệu y tế	7
2.2.1	Số chiều cao	7
2.2.2	Mất cân bằng lớp	8
2.2.3	Tính phi tuyến	8
2.3	Kỹ thuật trực quan hóa của dữ liệu	9
2.3.1	t-SNE (t-Distributed Stochastic Neighbor Embedding)	9
2.3.2	UMAP (Uniform Manifold Approximation and Projection)	9
2.4	Kỹ thuật lựa chọn đặc trưng	9
2.5	Các mô hình phân loại	11

2.5.1	Logistic Regression	11
2.5.2	Mô hình SVM (Support Vector Machine)	15
2.5.3	Mô hình Random Forest	20
2.5.4	XGBoost (Extreme Gradient Boosting)	22
2.5.5	MLP (Multilayer Perceptron)	22
3	PHƯƠNG PHÁP NGHIÊN CỨU	29
3.1	Thiết lập thực nghiệm chung	29
3.2	Mô tả bộ dữ liệu	31
3.3	Pipeline Breast Cancer — Xử lý số chiều cao và phân tích phi tuyến	32
3.4	Pipeline Diabetes — Xử lý mất cân bằng lớp và phân tích phi tuyến	36
3.5	Tổng kết chương	39
	Tài liệu tham khảo	41

Danh Mục Các Hình và Biểu Đồ

Danh Mục Bảng

3.1	Không gian tìm kiếm siêu tham số của các mô hình.	30
3.2	Sơ đồ tổng quan Pipeline Breast Cancer.	33
3.3	Sơ đồ tổng quan Pipeline Diabetes.	37

DANH MỤC CÁC TỪ VIẾT TẮT

Từ viết tắt	Diễn giải
AUC	<i>Area Under the Curve</i> — Diện tích dưới đường cong ROC
EHR	<i>Electronic Health Records</i> — Hồ sơ bệnh án điện tử
GEO	<i>Gene Expression Omnibus</i> — Kho dữ liệu biểu hiện gen công khai
HER2	<i>Human Epidermal growth factor Receptor 2</i> — Phân nhóm ung thư vú HER2 dương tính
LR	<i>Logistic Regression</i> — Hồi quy logistic
ML	<i>Machine Learning</i> — Học máy
MLP	<i>Multi-layer Perceptron</i> — Mạng nơ-ron nhiều lớp
PCA	<i>Principal Component Analysis</i> — Phân tích thành phần chính
RF	<i>Random Forest</i> — Rừng ngẫu nhiên
ROC	<i>Receiver Operating Characteristic</i> — Đường cong đặc trưng vận hành bộ thu
SMOTE	<i>Synthetic Minority Over-sampling Technique</i> — Kỹ thuật tăng mẫu thiểu số tổng hợp
SMOTE+ENN	SMOTE kết hợp <i>Edited Nearest Neighbours</i>
SVM	<i>Support Vector Machine</i> — Máy vectơ hỗ trợ
TNBC	<i>Triple-Negative Breast Cancer</i> — Ung thư vú ba âm tính
t-SNE	<i>t-distributed Stochastic Neighbor Embedding</i>
UMAP	<i>Uniform Manifold Approximation and Projection</i>
XGBoost	<i>Extreme Gradient Boosting</i>

DANH SÁCH THUẬT NGỮ

Thuật ngữ	Tên gốc	Ý nghĩa
Độ chính xác	Accuracy	Tỷ lệ mẫu được phân loại đúng trên tổng số mẫu.
Mất cân bằng lớp	Class imbalance	Hiện tượng một nhãn lớp có số lượng mẫu ít hơn đáng kể so với nhãn còn lại.
Lời nguyền đa chiều	Curse of dimensionality	Hiện tượng dữ liệu trở nên thừa thớt và khoảng cách giữa các điểm mất ý nghĩa khi số chiều tăng cao.
Lựa chọn đặc trưng	Feature selection	Quá trình chọn một tập con các đặc trưng có liên quan nhất để xây dựng mô hình học máy hiệu quả hơn.
Điểm F1	F1-score	Trung bình điều hòa của Precision và Recall, thường dùng để đánh giá mô hình trên dữ liệu mất cân bằng.
Biểu hiện gen	Gene expression	Mức độ hoạt động của gen trong tế bào, thường được đo bằng lượng mRNA được tổng hợp.
Siêu tham số	Hyperparameter	Tham số của mô hình được thiết lập trước khi huấn luyện, không được cập nhật trong quá trình học.
Hàm nhân	Kernel	Hàm đo mức độ tương đồng, cho phép SVM học ranh giới phi tuyến mà không cần biến đổi tường minh sang không gian đặc trưng chiều cao.
Lớp đa số	Majority class	Lớp nhãn có số lượng mẫu lớn hơn trong bài toán mất cân bằng.
Lớp thiểu số	Minority class	Lớp nhãn có số lượng mẫu ít hơn trong bài toán mất cân bằng, thường là lớp cần phát hiện (ví dụ: ca bệnh).
Khớp quá mức	Overfitting	Mô hình ghi nhớ chi tiết và nhiễu từ tập huấn luyện, làm giảm khả năng tổng quát hóa trên dữ liệu mới.
Độ chính xác dự đoán dương	Precision	Tỷ lệ dự đoán dương tính đúng trên tổng số dự đoán dương tính của mô hình.
Độ bao phủ	Recall	Tỷ lệ mẫu dương tính thực sự được mô hình phân loại đúng.
Lấy mẫu lại	Resampling	Kỹ thuật điều chỉnh phân phối lớp trong tập huấn luyện thông qua tăng (oversampling) hoặc giảm (undersampling) số lượng mẫu.

THÔNG TIN KHÓA LUẬN TỐT NGHIỆP

Tên đề tài:	Mô hình dự đoán cho dữ liệu chăm sóc sức khỏe
Ngành:	Toán học
Chuyên ngành:	Khoa học Dữ liệu
Khóa:	2022
Sinh viên:	Lê Vũ Uyển Nhi (MSSV: 22110145)
GVHD:	TS. Tô Đức Khánh
Cơ sở đào tạo:	Trường Đại học Khoa học Tự nhiên, ĐHQG TP. HCM
Năm bảo vệ:	2026

Tóm tắt:

Khóa luận nghiên cứu và đánh giá hiệu quả của các mô hình học máy trên hai bộ dữ liệu y tế đặc trưng. Bộ dữ liệu thứ nhất, Breast Cancer Gene Expression (GSE45827), gồm 151 mẫu bệnh nhân với 54.676 đặc trưng gen, tiêu biểu cho bài toán số chiều cao (*large p, small n*). Bộ dữ liệu thứ hai, Diabetes Health Indicators, mang tính chất mất cân bằng lớp nghiêm trọng. Khóa luận khảo sát ba hướng chính: (1) đánh giá tác động của feature selection đến hiệu năng phân loại; (2) đánh giá kỹ thuật resampling SMOTE và SMOTE+ENN; (3) so sánh hiệu năng năm mô hình học máy: Logistic Regression, SVM, Random Forest, XGBoost và MLP. Kết quả cho thấy ... (*bổ sung sau khi hoàn thiện thực nghiệm*).

Từ khóa: học máy, dữ liệu y tế, ung thư vú, biểu hiện gen, tiểu đường, lựa chọn đặc trưng, mất cân bằng lớp, SMOTE, XGBoost, SVM.

THESIS INFORMATION

Title:	Predictive Models for Healthcare Data
Major:	Mathematics
Specialization:	Data Science
Cohort:	2022
Student:	Le Vu Uyen Nhi (Student ID: 22110145)
Supervisor:	Dr. To Duc Khanh
Institution:	University of Science, Vietnam National University Ho Chi Minh City
Year:	2026

Abstract:

This thesis investigates and evaluates the effectiveness of machine learning models on two representative healthcare datasets with complex characteristics inherent to medical data. The first dataset, Breast Cancer Gene Expression (GSE45827), contains 151 patient samples described by 54,676 gene features, representing a high-dimensional classification problem (*large p , small n*). The second dataset, Diabetes Health Indicators, exhibits severe class imbalance. Three main research directions are explored: (1) evaluating the impact of feature selection on classification performance in high-dimensional settings; (2) assessing the effectiveness of resampling techniques (SMOTE and SMOTE+ENN) for handling class imbalance; and (3) comparing five machine learning models — Logistic Regression, SVM (RBF kernel), Random Forest, XGBoost, and MLP — through t-SNE and UMAP visualizations alongside quantitative metrics. Results indicate that ... *(to be completed upon finalization of experiments)*.

Keywords: machine learning, healthcare data, breast cancer, gene expression, diabetes, feature selection, class imbalance, SMOTE, XGBoost, SVM.

Chương 1

Giới thiệu

Chương này trình bày lý do lựa chọn đề tài, mục tiêu nghiên cứu, đối tượng và phạm vi thực hiện của khóa luận. Từ thực trạng dữ liệu y tế có tính phức tạp với các đặc tính phi tuyến, số chiều cao và mất cân bằng lớp, đề tài đặt ra vấn đề cần khảo sát hiệu quả của các mô hình học máy trong bài toán dự đoán trên hai bộ dữ liệu chăm sóc sức khỏe có đặc trưng riêng biệt. Phạm vi chính của khóa luận là đánh giá và so sánh hiệu suất của các mô hình học máy khác nhau, bao gồm cả các mô hình truyền thống và hiện đại, trong việc dự đoán kết quả lâm sàng trên hai bộ dữ liệu chăm sóc sức khỏe.

1.1 Lý do chọn đề tài

Trong thập kỷ vừa qua, ngành y tế đang trải qua một cuộc chuyển đổi số sâu rộng. Sự phát triển của hồ sơ bệnh án điện tử (Electronic Health Records), công nghệ trình tự gene và các thiết bị theo dõi sức khỏe đã tạo ra một lượng dữ liệu khổng lồ mà các phương pháp phân tích truyền thống không còn đủ khả năng xử lý hiệu quả. Trong bối cảnh đó, các mô hình học máy nổi lên như một công cụ đầy tiềm năng để khai thác giá trị từ những nguồn dữ liệu này. Đơn cử như theo khảo sát của Bajwa và cộng sự (2021), trí tuệ nhân tạo và học máy đã được ứng dụng rộng rãi trong chẩn đoán bệnh, dự đoán nguy cơ bệnh lý, phân tích hình ảnh y tế và hỗ trợ ra quyết định lâm sàng.[1]

Tiềm năng ứng dụng của học máy trong y tế phụ thuộc rất lớn vào đặc tính của dữ liệu đầu vào. Khác với dữ liệu trong nhiều lĩnh vực khác, dữ liệu y tế thường tồn tại các đặc điểm phức tạp khiến các mô hình học máy thông thường không thể trực tiếp áp dụng mà không có bước tiền xử lý phù hợp. Trong phạm vi đề tài này, ba đặc tính được xác định là trực tiếp ảnh hưởng đến hai bộ dữ liệu được nghiên cứu, bao gồm: tính phi tuyến, số chiều cao (high-dimensional data) và mất cân bằng giữa các lớp.

Về số chiều cao, dữ liệu biểu hiện gen, loại dữ liệu phản ánh mức độ hoạt động của từng gen trong tế bào, là một trong những nguồn dữ liệu y tế phổ biến nhất trong nghiên cứu ung thư. Đặc điểm nổi bật của loại dữ liệu này là số lượng đặc trưng (gen) thường lên đến hàng chục nghìn, trong khi số lượng mẫu (bệnh nhân) chỉ ở mức vài trăm. Tình trạng đặc trưng lớn nhưng số lượng mẫu lại nhỏ này dẫn đến hiện tượng "lời nguyền đa

chiều": khi không gian đặc trưng quá rộng so với lượng dữ liệu có sẵn, các mô hình học máy có xu hướng học thuộc dữ liệu huấn luyện thay vì nắm bắt quy luật thực sự, từ đó giảm đi khả năng tổng quát hóa trên dữ liệu mới của nó, hay còn gọi là hiện tượng học vẹt. Vì vậy, bước tiền xử lý, đặc biệt là lựa chọn đặc trưng đóng vai trò then chốt. Nghiên cứu của Bolon-Canedo và cộng sự đã chỉ ra rằng việc lựa chọn phương pháp chọn đặc trưng phù hợp có ảnh hưởng quyết định đến hiệu năng phân loại.[2]

Về tính phi tuyến, mối quan hệ giữa các đặc trưng sinh học và kết quả lâm sàng thường không thể biểu diễn bằng hàm tuyến tính đơn giản. Trong dữ liệu biểu hiện gen, các gen tương tác với nhau theo những cơ chế điều hòa phức tạp, tạo ra các mẫu phi tuyến trong không gian đặc trưng. Điều này đặt ra câu hỏi thực tiễn: liệu các mô hình phi tuyến như SVM với kernel RBF, Random Forest hay XGBoost có thực sự vượt trội so với mô hình tuyến tính như Logistic Regression trên dữ liệu y tế hay không, và ở mức độ nào?

Về mất cân bằng lớp, đây là vấn đề cố hữu của hầu hết bài toán phát hiện bệnh trong y tế: số ca bệnh (lớp thiểu số) luôn ít hơn nhiều so với ca không bệnh (lớp đa số). Sadeghi và cộng sự (2022) đã chỉ ra rằng mô hình học máy huấn luyện trên dữ liệu mất cân bằng thường đạt độ chính xác cao nhưng lại có độ bao phủ rất thấp trên lớp thiểu số, tức là bỏ sót phần lớn ca bệnh thực sự.[3] Đây là kết quả không thể chấp nhận được trong bối cảnh y tế vì việc bỏ sót chẩn đoán có thể ảnh hưởng trực tiếp đến tính mạng bệnh nhân.

Xuất phát từ những vấn đề trên, đề tài được thực hiện nhằm khảo sát một cách hệ thống hiệu quả của các mô hình học máy trên hai bộ dữ liệu y tế có đặc tính đại diện: bộ dữ liệu Breast Cancer Gene Expression với số chiều cao và tính phi tuyến, và bộ dữ liệu Diabetes Health Indicators với hiện tượng mất cân bằng lớp. Cụ thể, đề tài tập trung vào ba hướng khảo sát chính: (1) đánh giá tác động của feature selection đến hiệu năng phân loại trên dữ liệu số chiều cao, (2) đánh giá tác động của resampling đến khả năng phát hiện minority class trên dữ liệu mất cân bằng, và (3) trực quan hóa và so sánh hiệu năng mô hình trên cả hai bộ dữ liệu, nhằm làm rõ mức độ ảnh hưởng của từng đặc tính dữ liệu đến kết quả phân loại.

1.2 Mục tiêu nghiên cứu

Đề tài hướng đến bốn mục tiêu cụ thể sau:

- Khảo sát và xử lý vấn đề số chiều cao trên bộ dữ liệu Breast Cancer Gene Expression (Biểu hiện gen của ung thư vú) thông qua hai nhóm phương pháp lựa chọn đặc trưng:
- Phân tích tính phi tuyến trên cả hai bộ dữ liệu thông qua trực quan hóa t-SNE và UMAP, kết hợp với phân tích đặc trưng quan trọng của các mô hình tree-based. Mức độ vượt trội của mô hình phi tuyến so với Logistic Regression sẽ được dùng làm bằng chứng định lượng cho tính phi tuyến của dữ liệu.
- Khảo sát ảnh hưởng của mất cân bằng lớp và so sánh hai kỹ thuật resampling —

SMOTE và SMOTE+ENN — trên bộ dữ liệu Diabetes Health Indicators, đánh giá mức độ cải thiện F1-score và ROC-AUC so với baseline không resampling.

- So sánh hiệu năng của năm mô hình học máy trên cả hai pipeline: Logistic Regression, SVM (kernel RBF), Random Forest, XGBoost và Multi-layer Perceptron (MLP). Mục tiêu là xác định mô hình nào ổn định nhất trong bối cảnh dữ liệu y tế có đặc tính phức tạp.

1.3 Đối tượng và phạm vi nghiên cứu

Đề tài sử dụng hai bộ dữ liệu healthcare được lấy từ các kho dữ liệu công khai, mỗi bộ đại diện cho một nhóm thách thức đặc thù của dữ liệu y tế.

1.3.1 Breast Cancer Gene Expression Dataset (GSE45827 - CuMiDa)

Bộ dữ liệu GSE45827 được thu thập từ cơ sở dữ liệu CuMiDa (Curated Microarray Database), một kho dữ liệu microarray đã được làm sạch và tuyển chọn từ GEO nhằm phục vụ cho các nghiên cứu và đánh giá mô hình học máy trong lĩnh vực ung thư. Bộ dữ liệu gồm 151 mẫu bệnh nhân, trong đó mỗi mẫu được mô tả bởi 54.676 đặc trưng gen. Các mẫu được chia thành nhiều nhóm tương ứng với các phân nhóm ung thư vú khác nhau, bao gồm TNBC, HER2, Luminal A, Luminal B và mô bình thường. Một đặc điểm quan trọng của bộ dữ liệu là số lượng đặc trưng rất lớn so với số lượng mẫu. Cụ thể, trung bình mỗi mẫu có khoảng 362 đặc trưng gene trên một quan sát, tạo nên bài toán có số lượng đặc trưng lớn, số lượng mẫu nhỏ. Trong các bài toán như vậy, mô hình học máy thường gặp khó khăn do dữ liệu có độ chiều cao, dễ xảy ra hiện tượng overfitting và làm giảm khả năng tổng quát hóa trên dữ liệu mới. Vì vậy, việc áp dụng các kỹ thuật lựa chọn đặc trưng và giảm chiều dữ liệu là cần thiết trước khi xây dựng mô hình dự đoán.

1.3.2 Diabetes Health Indicators Dataset (BRFSS 2015 - CDC)

Bộ dữ liệu được xây dựng từ cuộc khảo sát BRFSS 2015 (Behavioral Risk Factor Surveillance System) do CDC (Centers for Disease Control and Prevention) thực hiện hàng năm nhằm thu thập thông tin về hành vi sức khỏe và các bệnh mãn tính của người dân Mỹ. Bộ dữ liệu gồm 253.680 mẫu khảo sát với 21 đặc trưng đầu vào, bao gồm các chỉ số lâm sàng và hành vi như BMI, huyết áp, cholesterol, mức độ hoạt động thể chất, thói quen hút thuốc và tiền sử bệnh tim mạch. Nhân lớp phân thành 2 nhóm: không mắc tiểu đường và tiểu đường, với mức độ mất cân bằng rõ rệt giữa hai nhóm này (tỉ lệ xấp xỉ 86:14). Theo thống kê của IDF (2021), có khoảng 537 triệu người mắc tiểu đường trên toàn cầu và con số này được dự báo tăng lên 783 triệu vào năm 2045,[5] cho thấy tầm quan trọng của các mô hình dự đoán sớm cho căn bệnh này.

1.3.3 Phạm vi nghiên cứu

Để đảm bảo tính khả thi và chiều sâu của thực nghiệm, đề tài được giới hạn trong các phạm vi sau:

- Chỉ sử dụng các phương pháp Supervised Learning cho bài toán phân loại. Các phương pháp *Unsupervised Learning* như clustering hay anomaly detection không phải là đối tượng đánh giá chính của nghiên cứu.
- Không nghiên cứu chuyên sâu về Deep Learning. Mô hình MLP được sử dụng như một mạng nơ-ron nông nhằm làm đường cơ sở để so sánh với các mô hình học máy truyền thống, thay vì tối ưu hóa kiến trúc mạng nơ-ron.
- Không triển khai hệ thống trong môi trường bệnh viện thực tế. Toàn bộ thực nghiệm được thực hiện trong môi trường nghiên cứu bằng ngôn ngữ Python với các thư viện chính gồm `scikit-learn`, `XGBoost`, `imbalanced-learn`, `matplotlib` và `seaborn`.
- Kỹ thuật lựa chọn đặc trưng chỉ được áp dụng cho bộ dữ liệu Breast Cancer, trong khi các phương pháp tái lấy mẫu được áp dụng cho bộ dữ liệu Diabetes nhằm xử lý hiện tượng mất cân bằng lớp. Việc khảo sát tính phi tuyến được thực hiện trên cả hai pipeline nghiên cứu.

1.3.4 Nội dung thực hiện

Khóa luận được tổ chức thành hai pipeline thực nghiệm độc lập, mỗi pipeline tập trung giải quyết một nhóm vấn đề đặc thù của dữ liệu y tế. Nội dung thực hiện bao gồm các bước chính sau:

- **Tiền xử lý dữ liệu:** xử lý giá trị thiếu, chuẩn hóa dữ liệu bằng `StandardScaler` và mã hóa nhãn. Tất cả các bước tiền xử lý được huấn luyện trên tập train và áp dụng sang tập test.
- **Trực quan hóa và phân tích tính phi tuyến:** sử dụng các kỹ thuật giảm chiều t-SNE và UMAP để chiếu dữ liệu xuống không gian hai chiều, từ đó quan sát khả năng phân tách giữa các lớp và đánh giá đặc tính phi tuyến của dữ liệu. Bước này được áp dụng cho cả hai pipeline.
- **Lựa chọn đặc trưng (Pipeline Breast Cancer):** so sánh các phương pháp thuộc nhóm filter gồm `Variance Threshold` và `SelectKBest` với phương pháp wrapper `RFECV`. Hiệu năng mô hình được đánh giá trên ba phiên bản dữ liệu gồm dữ liệu gốc, dữ liệu sau filter và dữ liệu sau wrapper.
- **Xử lý mất cân bằng lớp (Pipeline Diabetes):** so sánh hiệu quả của các phương pháp `SMOTE` và `SMOTE+ENN` với trường hợp không sử dụng tái lấy mẫu trên năm mô hình phân loại.
- **Huấn luyện và tối ưu mô hình:** năm mô hình gồm Logistic Regression, SVM RBF, Random Forest, XGBoost và MLP được huấn luyện bằng phương pháp *Stratified K-Fold Cross-Validation* ($k = 5$) kết hợp với `GridSearchCV` để tối ưu siêu tham số.

- **Đánh giá và thảo luận kết quả:** so sánh hiệu năng các mô hình dựa trên các độ đo Accuracy, F1-score, ROC-AUC và Confusion Matrix. Đồng thời phân tích tầm quan trọng của đặc trưng (*feature importance*) để đối chiếu với kết quả trực quan hóa và đặc điểm của dữ liệu.

1.3.5 Bố cục khóa luận

Khóa luận được tổ chức thành năm chương như sau:

- **Chương 1 – Giới thiệu:** trình bày bối cảnh nghiên cứu, lý do lựa chọn đề tài, mục tiêu nghiên cứu và phạm vi thực hiện.
- **Chương 2 – Cơ sở lý thuyết:** trình bày các kiến thức nền tảng liên quan đến dữ liệu y tế, các kỹ thuật trực quan hóa dữ liệu, lựa chọn đặc trưng, các mô hình phân loại, kỹ thuật xử lý mất cân bằng lớp và các độ đo đánh giá mô hình.
- **Chương 3 – Phương pháp nghiên cứu:** mô tả chi tiết quy trình thực nghiệm của từng pipeline, thiết lập thực nghiệm, quy trình xử lý dữ liệu và các câu hỏi nghiên cứu được đặt ra.
- **Chương 4 – Kết quả thực nghiệm:** trình bày và phân tích kết quả đạt được trên từng pipeline, đồng thời thực hiện so sánh tổng hợp giữa các pipeline nghiên cứu.
- **Chương 5 – Kết luận và hướng phát triển:** tổng kết các kết quả chính của khóa luận, nêu các hạn chế còn tồn tại và đề xuất những hướng nghiên cứu tiếp theo.

Chương 2

Cơ sở lý thuyết

2.1 Tổng quan về ứng dụng học máy trong việc dự đoán dữ liệu chăm sóc sức khỏe

Trong những năm gần đây, việc ứng dụng học máy trong lĩnh vực chăm sóc sức khỏe đã trở thành một xu hướng nổi bật, mang lại nhiều lợi ích trong việc dự đoán và chẩn đoán các bệnh lý. Học máy, với khả năng xử lý và phân tích dữ liệu lớn, đã được sử dụng để xây dựng các mô hình dự đoán chính xác về tình trạng sức khỏe của bệnh nhân, từ đó hỗ trợ các quyết định lâm sàng và cải thiện chất lượng chăm sóc.

2.2 Đặc tính của dữ liệu y tế

Dữ liệu y tế không chỉ lớn về quy mô mà còn phức tạp về cấu trúc, đặt ra nhiều thách thức đặc thù cho các mô hình học máy. Trong số đó, ba đặc tính dưới đây được xác định là các vấn đề trọng tâm cần giải quyết trong phạm vi khóa luận này, xuất phát trực tiếp từ đặc trưng của hai bộ dữ liệu được sử dụng: số chiều cao và tính phi tuyến là vấn đề chủ đạo của bộ Breast Cancer Gene Expression, trong khi mất cân bằng lớp và tính phi tuyến là đặc trưng nổi bật của bộ Diabetes Health Indicators. Mỗi đặc tính được trình bày theo cấu trúc: định nghĩa, hậu quả đối với mô hình và hướng xử lý trong đề tài.

2.2.1 Số chiều cao

Dữ liệu số chiều cao là dữ liệu có số lượng đặc trưng lớn hơn đáng kể so với số lượng mẫu. Trong lĩnh vực y tế, đây là đặc điểm phổ biến của nhiều loại dữ liệu sinh học, điển hình là dữ liệu biểu hiện gen trong đó mỗi mẫu bệnh nhân được mô tả bởi hàng chục nghìn giá trị biểu hiện gen trong khi số lượng bệnh nhân trong nghiên cứu thường chỉ ở mức vài trăm. Tình trạng này dẫn đến hiện tượng "lời nguyền đa chiều" (curse of dimensionality), khi số chiều tăng, không gian đặc trưng trở nên cực kỳ thưa thớt, khoảng cách giữa các điểm dữ liệu dần mất ý nghĩa thống kê, khiến nhiều thuật toán dựa trên khoảng cách như KNN suy giảm hiệu năng rõ rệt. Đồng thời, khi số đặc trưng vượt xa số mẫu, mô hình có quá nhiều bậc tự do so với lượng thông tin có sẵn, dẫn đến nguy cơ overfitting

cao, tức mô hình học thuộc dữ liệu huấn luyện thay vì nắm bắt quy luật thực sự, làm giảm khả năng tổng quát hóa trên dữ liệu mới. Ngoài ra, nhiều đặc trưng trong không gian số chiều cao thường là nhiễu hoặc dư thừa, không mang thông tin phân biệt có ý nghĩa, gây khó khăn cho quá trình học của mô hình.

Trong phạm vi khóa luận, nhóm áp dụng các phương pháp lựa chọn đặc trưng để giữ lại các đặc trưng thực sự có giá trị phân biệt, loại bỏ nhiễu và đặc trưng dư thừa. Điểm nổi bật của phương pháp lựa chọn đặc trưng là nó giữ nguyên các đặc trưng gốc mà không biến đổi chúng, qua đó bảo toàn khả năng giải thích của từng đặc trưng, đặc biệt quan trọng trong bối cảnh y tế khi cần truy xuất ý nghĩa sinh học của từng gene được chọn. Chi tiết các phương pháp được trình bày tại mục 2.4.

2.2.2 Mất cân bằng lớp

Mất cân bằng lớp là hiện tượng số lượng mẫu giữa các lớp chênh lệch đáng kể, trong đó lớp thiểu số chiếm tỉ lệ rất nhỏ so với lớp đa số. Trong dữ liệu y tế, đây là đặc điểm phổ biến xuất phát từ sự chênh lệch tự nhiên giữa tỉ lệ mắc bệnh và tỉ lệ không mắc bệnh trong dân số, lớp dương tính (bệnh nhân mắc bệnh) thường chiếm tỉ lệ nhỏ hơn nhiều so với lớp âm tính (người bình thường). Khi dữ liệu mất cân bằng, các mô hình học máy có xu hướng thiên vị về phía lớp đa số vì dự đoán toàn bộ mẫu là lớp đa số đã cho độ chính xác (Accuracy) tổng thể cao. Hệ quả là mô hình thất bại trong việc nhận diện đúng các trường hợp thuộc lớp thiểu số, vốn là mục tiêu quan trọng nhất trong bối cảnh y tế: bỏ sót một ca bệnh thường gây hậu quả nghiêm trọng hơn nhiều so với cảnh báo nhầm. Điều này khiến Accuracy trở thành độ đo không phù hợp khi dữ liệu mất cân bằng, và các độ đo như F1-score và ROC-AUC cần được ưu tiên thay thế.

Trong phạm vi khóa luận, nhóm áp dụng hai kỹ thuật tái cân bằng dữ liệu trên tập huấn luyện: dùng kỹ thuật SMOTE tạo mẫu tổng hợp cho lớp thiểu số bằng cách nội suy giữa các điểm lân cận, và kỹ thuật SMOTE+ENN kết hợp thêm bước làm sạch biên quyết định nhằm loại bỏ các mẫu nhiễu trong vùng chồng lấp giữa hai lớp. Cả hai kỹ thuật chỉ được áp dụng trên tập huấn luyện để tránh việc dữ liệu được cho trước kết quả, hay còn gọi là data leakage. Chi tiết được trình bày tại mục 2.6.

2.2.3 Tính phi tuyến

Tính phi tuyến là đặc điểm của dữ liệu trong đó mối quan hệ giữa các đặc trưng đầu vào và nhãn lớp không thể biểu diễn bằng một hàm tuyến tính đơn giản. Trong thực tế lâm sàng, đây là quy luật phổ biến hơn là ngoại lệ, chẳng hạn như tác động của liều lượng thuốc lên hiệu quả điều trị, mối liên hệ giữa chỉ số BMI và nguy cơ mắc bệnh tim mạch, hay sự tương tác giữa tuổi tác và các chỉ số sinh hóa, tất cả đều mang tính phi tuyến rõ rệt. Trong dữ liệu biểu hiện gen, các gen không hoạt động độc lập mà tương tác với nhau theo các mạng lưới điều hòa phức tạp, tạo ra cấu trúc phi tuyến đặc trưng trong không gian đặc trưng. Việc này khiến các mô hình tuyến tính như Logistic Regression không đủ khả năng nắm bắt các mối quan hệ phức tạp này, dẫn đến sai lệch hệ thống trong dự đoán và hiệu năng thấp hơn so với các mô hình phi tuyến. Tuy nhiên, tính phi tuyến

không phải lúc nào cũng hiển thị rõ ràng từ dữ liệu thô, cần có các phương pháp phân tích và trực quan hóa phù hợp để xác nhận sự tồn tại của nó trước khi lựa chọn mô hình.

Trong phạm vi khóa luận, nhóm khảo sát tính phi tuyến trên cả hai bộ dữ liệu thông qua ba hướng bổ trợ nhau. Thứ nhất, trực quan hóa t-SNE và UMAP để quan sát cấu trúc phân tách giữa các lớp trong không gian 2D phi tuyến. Thứ hai, so sánh learning curve của Logistic Regression với các mô hình phi tuyến (Random Forest, XGBoost) — nếu Logistic Regression đạt trần hiệu năng thấp hơn rõ rệt, đây là bằng chứng thực nghiệm xác nhận dữ liệu có cấu trúc phi tuyến mà mô hình tuyến tính không thể nắm bắt. Thứ ba, phân tích feature importance của Random Forest và XGBoost để xác định các đặc trưng đóng vai trò phân biệt chính, phản ánh cấu trúc phi tuyến có tổ chức trong dữ liệu.

2.3 Kỹ thuật trực quan hóa của dữ liệu

Đối với các dữ liệu số chiều cao, trực quan hóa trực tiếp trong không gian gốc là không khả thi do con người chỉ có thể nhận thức trực quan ở tối đa 3 chiều. Các kỹ thuật giảm chiều tuyến tính như PCA có thể chiếu dữ liệu xuống 2D nhưng chỉ bảo toàn phương sai tuyến tính, do đó dễ bỏ sót các cấu trúc phi tuyến phức tạp vốn đặc trưng của dữ liệu y tế. Vì vậy, đề tài sử dụng hai kỹ thuật chiếu phi tuyến là t-SNE và UMAP để quan sát cấu trúc phân bố dữ liệu trong không gian 2D — nhằm phân tích khả năng phân tách giữa các lớp và thu thập bằng chứng ban đầu về tính phi tuyến, không dùng để huấn luyện mô hình.

2.3.1 t-SNE (t-Distributed Stochastic Neighbor Embedding)

2.3.2 UMAP (Uniform Manifold Approximation and Projection)

2.4 Kỹ thuật lựa chọn đặc trưng

Lựa chọn đặc trưng (*feature selection*) là bước tiền xử lý quan trọng nhằm xác định tập con các biến đầu vào có đóng góp thực sự vào việc dự đoán nhãn lớp, đồng thời loại bỏ các đặc trưng nhiễu, dư thừa hoặc không liên quan. Trong bối cảnh dữ liệu biểu hiện gen với số chiều lên đến hàng chục nghìn gene, việc lựa chọn đặc trưng hiệu quả giúp giảm thiểu hiện tượng quá khớp (*overfitting*), rút ngắn thời gian huấn luyện và cải thiện khả năng tổng quát hóa của mô hình.

Đề tài áp dụng hai nhóm phương pháp lựa chọn đặc trưng: **Filter Method** và **Wrapper Method**. Hai nhóm này được kết hợp theo thứ tự nhằm tận dụng ưu điểm của từng phương pháp — lọc thô nhanh trước, sau đó chọn tinh bằng mô hình học máy.

Filter Method: Variance Threshold và SelectKBest với ANOVA F-test

Filter Method đánh giá từng đặc trưng dựa trên các tiêu chí thống kê, độc lập với mô hình học máy. Phương pháp này có chi phí tính toán thấp và phù hợp để xử lý dữ liệu chiều cao trong bước sơ lọc.

Variance Threshold loại bỏ các đặc trưng có phương sai thấp hơn một ngưỡng định trước θ . Phương sai của đặc trưng j được tính theo công thức:

$$\text{Var}(X_j) = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 \quad (2.1)$$

trong đó n là số mẫu, x_{ij} là giá trị của đặc trưng j tại mẫu thứ i , và $\bar{x}_j$ là giá trị trung bình của đặc trưng j . Đặc trưng có phương sai gần bằng 0 thể hiện giá trị gần như không thay đổi giữa các mẫu, do đó không mang thông tin phân biệt lớp.

Sau bước lọc phương sai, **SelectKBest** với hàm chấm điểm `f_classif` được sử dụng để chọn ra k đặc trưng có điểm ANOVA F-test cao nhất. ANOVA F-test (*Analysis of Variance F-test*) đánh giá mức độ phân biệt giữa các nhóm lớp dựa trên phương sai liên nhóm so với phương sai nội nhóm:

$$F = \frac{\text{MS}_{\text{between}}}{\text{MS}_{\text{within}}} = \frac{\sum_{c=1}^C n_c (\bar{x}_c - \bar{x})^2 / (C - 1)}{\sum_{c=1}^C \sum_{i \in c} (x_i - \bar{x}_c)^2 / (n - C)} \quad (2.2)$$

trong đó C là số lớp, n_c là số mẫu thuộc lớp c , $\bar{x}_c$ là giá trị trung bình của đặc trưng trong lớp c , và $\bar{x}$ là giá trị trung bình toàn bộ. Giá trị F càng lớn cho thấy đặc trưng có khả năng phân biệt lớp càng tốt. Trong thực nghiệm, các giá trị $k \in \{50, 100, 200, 500\}$ được thử nghiệm thông qua tìm kiếm siêu tham số (*hyperparameter search*) để xác định tập đặc trưng tối ưu.

Wrapper Method: RFECV với Random Forest

Wrapper Method đánh giá tập con đặc trưng thông qua hiệu năng thực tế của một mô hình học máy cụ thể, do đó phản ánh trực tiếp ích lợi của đặc trưng đối với nhiệm vụ phân loại.

Đề tài sử dụng **RFECV** (*Recursive Feature Elimination with Cross-Validation*) với mô hình nền là **RandomForestClassifier**. RFECV hoạt động theo nguyên tắc đệ quy: ở mỗi vòng lặp, mô hình được huấn luyện và các đặc trưng kém quan trọng nhất bị loại bỏ, quá trình tiếp tục cho đến khi tìm được tập đặc trưng tối ưu theo đánh giá chéo. Tầm quan trọng của đặc trưng trong Random Forest được xác định dựa trên mức độ giảm tạp chất trung bình (*Mean Decrease in Impurity*) qua tất cả các cây quyết định:

$$\text{Importance}(X_j) = \frac{1}{T} \sum_{t=1}^T \sum_{s \in S_t(j)} \Delta \text{Gini}(s) \quad (2.3)$$

trong đó T là số cây trong rừng, $\mathcal{S}_t(j)$ là tập hợp các nút phân tách sử dụng đặc trưng j trong cây t , và $\Delta\text{Gini}(s)$ là mức giảm chỉ số Gini tại nút s .

Cụ thể, quá trình thực nghiệm sử dụng `StratifiedKFold` với $k = 5$ fold để đảm bảo tỉ lệ nhãn được giữ nguyên trong từng fold, chỉ số đánh giá là `f1_weighted` phù hợp với dữ liệu có thể mất cân bằng nhãn, tham số `step = 0.1` để mỗi vòng loại bỏ 10% số đặc trưng còn lại, và `min_features_to_select = 10` nhằm đảm bảo số đặc trưng tối thiểu được giữ lại. `RFECV` tự động xác định số lượng đặc trưng tối ưu thông qua đường cong hiệu năng theo số đặc trưng.

Vai trò của lựa chọn đặc trưng trong dữ liệu biểu hiện gen

Bộ dữ liệu GSE45827 mang đặc trưng điển hình của dữ liệu biểu hiện gen: số chiều đặc trưng vượt trội so với số mẫu ($p \gg n$), trong đó phần lớn các gene không liên quan đến kiểu hình ung thư vú được phân tích. Nếu không có bước lọc đặc trưng, các mô hình phân loại dễ bị chi phối bởi nhiễu sinh học và hiện tượng *curse of dimensionality*. Việc kết hợp *Variance Threshold* để loại gene không biến động, *SelectKBest/ANOVA* để ưu tiên gene có liên hệ thống kê với nhãn lớp, và *RFECV* để tinh chỉnh tập đặc trưng theo hiệu năng mô hình thực tế, giúp giảm đáng kể số chiều đầu vào đồng thời nâng cao khả năng tổng quát hóa của toàn bộ pipeline phân loại.

2.5 Các mô hình phân loại

2.5.1 Logistic Regression

Khái niệm

Hồi quy logistic là một trong những thuật toán học máy có giám sát được sử dụng rộng rãi nhất trong lĩnh vực phân loại dữ liệu. Mặc dù mang tên hồi quy, mô hình này về bản chất là một phương pháp phân loại, được thiết kế để dự đoán xác suất thuộc về một lớp nhất định của biến mục tiêu rời rạc. Thuật toán này lần đầu tiên được giới thiệu trong lĩnh vực thống kê bởi nhà thống kê học David Cox vào năm 1958 và sau đó được tích hợp rộng rãi vào các hệ thống học máy hiện đại. Về mặt toán học, hồi quy logistic là một mô hình tuyến tính tổng quát, trong đó hàm liên kết là hàm logit. Mô hình này ánh xạ một tổ hợp tuyến tính của các biến đầu vào sang một giá trị xác suất nằm trong khoảng $(0, 1)$, nhờ đó cho phép đưa ra quyết định phân lớp dựa trên ngưỡng xác suất được xác định trước.

Dạng tổng quát của hàm tuyến tính tổng quát được biểu diễn như sau:

$$z = g(\mu) = \mathbf{w}^T \mathbf{x} + b \quad (2.4)$$

trong đó $\mu = E(Y|X)$ là giá trị kỳ vọng của biến phản hồi, $g(\cdot)$ là hàm liên kết, $\mathbf{x}$ là vector đặc trưng đầu vào, $\mathbf{w}$ là vector trọng số và b là hệ số chệch.

Thấy rằng, để dự đoán xác suất thuộc lớp dương, giá trị đầu ra z có thể nhận bất kỳ giá trị thực nào trong khoảng $(-\infty, +\infty)$. Điều này không phù hợp với yêu cầu của bài toán phân loại, bởi xác suất phải nằm trong khoảng $[0, 1]$. Ví dụ, mô hình tuyến tính có thể cho kết quả $z = 2.5$ hoặc $z = -1.3$, những giá trị không thể được diễn giải như xác suất. Mô hình logistic được xây dựng nhằm giải quyết các bài toán phân loại nhị phân, tức là bài toán trong đó biến phụ thuộc chỉ nhận một trong hai giá trị, thường được ký hiệu là 0 (âm tính) và 1 (dương tính). Việc quyết định lớp được thực hiện dựa trên một ngưỡng xác suất nhất định (thường là 0.5). Chẳng hạn, trong lĩnh vực y tế, mô hình có thể được sử dụng để dự đoán liệu một bệnh nhân có mắc bệnh tiểu đường hay không dựa trên các chỉ số sinh học. Hay trong lĩnh vực thể thao, mô hình có thể được sử dụng để dự đoán xác suất ghi bàn của một cú sút (vào hoặc không vào). Ngoài ra, trong tài chính, mô hình giúp xác định khả năng khách hàng có vỡ nợ hay không. Tất cả các quyết định này đều dựa trên giá trị xác suất được dự đoán bởi mô hình thông qua các đặc trưng đầu vào tương ứng.

Ngoài bài toán nhị phân, hồi quy logistic có thể được mở rộng sang bài toán phân loại đa lớp, tức là bài toán trong đó biến mục tiêu y có thể nhận một trong $K > 2$ giá trị rời rạc thay vì chỉ hai giá trị (0 hoặc 1) như thông thường. Bằng cách tiếp cận theo các hướng phổ biến như phân loại nhiều lớp với mỗi lớp là một bài toán nhị phân độc lập (One-vs-Rest) hoặc xây dựng các bộ phân loại trên từng cặp lớp (One-vs-One), hoặc mở rộng trực tiếp hàm sigmoid thành hàm softmax, hồi quy logistic có thể được áp dụng hiệu quả cho các bài toán phân loại đa lớp. Trong phạm vi luận văn này, đối với bộ dữ liệu Breast Cancer Gene Expression gồm sáu lớp phân loại, mô hình được triển khai dưới dạng hồi quy logistic đa lớp, trong đó hàm softmax được sử dụng để ước lượng xác suất thuộc về từng lớp. Lớp có xác suất dự đoán cao nhất sẽ được lựa chọn làm kết quả phân loại cuối cùng.

Hàm Sigmoid

Như đề cập ở trên, hàm sigmoid (còn gọi là hàm logistic) có thể được xem như là "trái tim" của mô hình hồi quy logistic. Hàm này được định nghĩa như sau:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (2.5)$$

trong đó z là giá trị đầu vào thực bất kỳ và e là cơ số của logarithm tự nhiên. Tính chất của hàm sigmoid là: (1) Miền giá trị của hàm nằm hoàn toàn trong khoảng $(0, 1)$, điều này khiến đầu ra của hàm có thể được diễn giải một cách tự nhiên như xác suất; (2) Hàm có dạng chữ S đơn điệu tăng, nghĩa là khi $z \rightarrow +\infty$ thì $\sigma(z) \rightarrow 1$, và khi $z \rightarrow -\infty$ thì $\sigma(z) \rightarrow 0$; (3) Tại $z = 0$, hàm cho giá trị $\sigma(0) = 0,5$, tương ứng với trạng thái không chắc chắn hoàn toàn giữa hai lớp.

Khi đạo hàm, hàm có dạng:

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)) \quad (2.6)$$

Khi đó, hàm có dạng thuận lợi trong tính toán, giúp đơn giản hóa đáng kể quá trình tối ưu hóa tham số bằng phương pháp lặp cập nhật tham số theo hướng giảm nhanh nhất của hàm mất mát (được đề cập tại mục 2.5.1). Về mặt ý nghĩa thực tiễn, hàm sigmoid đóng vai trò là cầu nối chuyển đổi một đầu ra tuyến tính không bị giới hạn thành một xác suất có ý nghĩa thống kê, khắc phục nhược điểm chính của hồi quy tuyến tính khi áp dụng trực tiếp cho bài toán phân loại.

Nguyên lý hoạt động

Hồi quy logistic hoạt động dựa trên ý tưởng cốt lõi là ước lượng xác suất có điều kiện $P(y = 1 | \mathbf{x})$, tức là xác suất để quan sát $\mathbf{x}$ thuộc về lớp dương tính. Thay vì dự đoán trực tiếp nhãn lớp, mô hình tính toán một giá trị xác suất liên tục, sau đó áp dụng một ngưỡng quyết định (thường là 0,5) để gán nhãn cuối cùng. Quá trình hoạt động của mô hình có thể được mô tả qua ba bước chính. Trước tiên, mô hình tính toán tổ hợp tuyến tính $z = \mathbf{w}^T \mathbf{x} + b$ từ các đặc trưng đầu vào. Tiếp theo, giá trị z được đưa qua hàm sigmoid để chuyển đổi thành xác suất $\hat{p} = \sigma(z)$. Cuối cùng, dựa trên $\hat{p}$, mô hình đưa ra quyết định phân lớp theo ngưỡng đã định.

Mô hình hồi quy logistic được định nghĩa hoàn chỉnh thông qua công thức sau:

$$\hat{p} = P(y = 1 | \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (2.7)$$

Trong đó:

- $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$: Vector đặc trưng đầu vào gồm n biến độc lập, mô tả các thuộc tính của mẫu dữ liệu cần phân loại.
- $\mathbf{w} = (w_1, w_2, \dots, w_n)^T \in \mathbb{R}^n$: Vector trọng số - các tham số học được từ dữ liệu huấn luyện. Mỗi w_i thể hiện mức độ ảnh hưởng của đặc trưng x_i đến xác suất dự đoán. Trọng số dương đồng nghĩa với việc đặc trưng tương ứng làm tăng xác suất thuộc lớp 1, trong khi trọng số âm thể hiện tác động ngược lại.
- $b \in \mathbb{R}$: Hệ số chệch - một hằng số cho phép mô hình linh hoạt trong việc dịch chuyển đường quyết định khỏi gốc tọa độ, giúp mô hình khớp tốt hơn với dữ liệu thực tế.
- $z = \mathbf{w}^T \mathbf{x} + b$: Giá trị tổng hợp tuyến tính, còn được gọi là *log-odds* hay *logit*, biểu thị logarithm của tỉ lệ xác suất:

$$z = \log\left(\frac{\hat{p}}{1 - \hat{p}}\right)$$

- $\hat{p}$: Xác suất ước lượng rằng mẫu $\mathbf{x}$ thuộc về lớp dương tính ($y = 1$).

Sau khi tính được xác suất $\hat{p}$, mô hình đưa ra quyết định phân lớp dựa trên ngưỡng quyết định τ (thường là 0,5) theo quy tắc:

$$\hat{y} = \begin{cases} 1 & \text{nếu } \hat{p} \geq \tau \\ 0 & \text{nếu } \hat{p} < \tau \end{cases} \quad (2.8)$$

Ngưỡng $\tau = 0,5$ là lựa chọn mặc định và hợp lý trong điều kiện dữ liệu cân bằng. Tuy nhiên, trong thực tế, khi bài toán yêu cầu độ nhạy cao - ví dụ: phát hiện ung thư, trong đó bỏ sót dương tính thật có chi phí rất cao - ngưỡng τ có thể được điều chỉnh xuống thấp hơn để tăng chỉ số Recall nhưng chấp nhận giảm độ chính xác (chỉ số Precision). Việc lựa chọn ngưỡng phù hợp thường được hỗ trợ bởi đường cong ROC và chỉ số AUC (chỉ số ROC-AUC được đề cập trong mục 2.2.2).

Hàm mất mát và phương pháp tối ưu

Như đã trình bày, mô hình cần xác định một tiêu chí đo lường mức độ sai lệch giữa xác suất mô hình dự đoán và nhãn thực tế trong tập dữ liệu. Hồi quy logistic sử dụng hàm mất mát Log-Loss, được dẫn xuất từ nguyên lý ước lượng hợp lý cực đại. Với tập huấn luyện gồm m mẫu, hàm mất mát được định nghĩa như sau:

$$\mathcal{L}(\mathbf{w}, b) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log \hat{p}^{(i)} + (1 - y^{(i)}) \log (1 - \hat{p}^{(i)}) \right] \quad (2.9)$$

trong đó m là số lượng mẫu huấn luyện, $y^{(i)}$ là nhãn thực tế và $\hat{p}^{(i)}$ là xác suất dự đoán của mẫu thứ i .

Về mặt trực quan, hàm này phạt nặng những trường hợp mô hình dự đoán sai với mức độ tự tin cao, chẳng hạn, dự đoán xác suất gần 0 cho một mẫu thực tế thuộc lớp dương, hoặc ngược lại. Hàm mất mát này có tính chất lồi đối với không gian tham số, đảm bảo rằng mọi nghiệm cực bộ cũng là nghiệm toàn cục — một tính chất quan trọng giúp quá trình tối ưu hóa hội tụ ổn định. Để cực tiểu hóa $\mathcal{L}$, phương pháp phổ biến nhất là gradient descent (tạm dịch là thuật toán hạ gradient), trong đó các tham số được cập nhật lặp đi lặp lại theo hướng ngược chiều gradient:

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \cdot \frac{\partial \mathcal{L}}{\partial \mathbf{w}}, \quad b \leftarrow b - \eta \cdot \frac{\partial \mathcal{L}}{\partial b} \quad (2.10)$$

trong đó $\eta > 0$ là tốc độ học - một siêu tham số kiểm soát bước dịch chuyển trong không gian tham số.

Ngoài ra, để tránh hiện tượng mô hình học vẹt, người ta thường bổ sung thêm các thành phần chính quy hóa (Regularization) vào hàm mất mát. Trong phạm vi khóa luận này, chính quy hóa L2 (*Ridge*) được sử dụng:

$$\mathcal{L}_{\text{reg}} = \mathcal{L} + \lambda \|\mathbf{w}\|_2^2 \quad (2.11)$$

trong đó $\lambda > 0$ là hệ số chính quy hóa, kiểm soát mức độ phạt đối với các trọng số lớn.

Ưu điểm

Hồi quy logistic có một số đặc điểm thuận lợi khiến mô hình này được sử dụng rộng rãi trong thực tế. Thứ nhất, mô hình có tính diễn giải cao: các hệ số w_i phản ánh trực tiếp tác động của từng đặc trưng đến log-odds của kết quả, cho phép phân tích ý nghĩa của từng biến đầu vào một cách tường minh. Nhờ đó, mô hình được ưu tiên trong các lĩnh vực đòi hỏi tính minh bạch như y tế - nơi cần giải thích nguy cơ mắc bệnh dựa trên chỉ số lâm sàng - hay tài chính, nơi khả năng lý giải kết quả cho các bên liên quan là yêu cầu bắt buộc trong các hệ thống chấm điểm tín dụng và phát hiện gian lận.

Thứ hai, mô hình có độ phức tạp tính toán thấp, phù hợp với các tập dữ liệu lớn. Do hàm mất mát có tính lồi, quá trình huấn luyện hội tụ ổn định và không phụ thuộc vào giá trị khởi tạo tham số. Ngoài ra, đầu ra dạng xác suất cho phép điều chỉnh ngưỡng quyết định linh hoạt, làm cho mô hình phù hợp với nhiều bài toán thực tế như dự đoán hành vi người dùng (dự đoán tỷ lệ khách hàng rời bỏ) hay phân loại văn bản (phát hiện tin rác, phân tích cảm xúc).

Hạn chế

Hồi quy logistic cũng tồn tại một số hạn chế cần lưu ý. Hạn chế cơ bản nhất là giả định tuyến tính: mô hình chỉ có khả năng học các ranh giới quyết định tuyến tính trong không gian đặc trưng, do đó hiệu suất có thể bị giới hạn với các bài toán có cấu trúc phi tuyến phức tạp. Ngoài ra, mô hình nhạy cảm với đa cộng tuyến — khi các biến đầu vào có tương quan cao với nhau, ước lượng tham số có thể trở nên không ổn định. Cuối cùng, trong bối cảnh dữ liệu mất cân bằng lớp, hiệu suất mô hình có thể suy giảm đáng kể nếu không áp dụng các kỹ thuật hỗ trợ phù hợp.

2.5.2 Mô hình SVM (Support Vector Machine)

Khái niệm

Support Vector Machine (SVM) là một thuật toán học máy có giám sát được phát triển bởi Vladimir Vapnik và Alexey Chervonenkis vào những năm 1960, sau đó được hoàn thiện và phổ biến rộng rãi thông qua công trình của Cortes và Vapnik năm 1995. SVM được xây dựng trên nền tảng lý thuyết tối thiểu hóa rủi ro có cấu trúc, nhằm tìm kiếm một mô hình không chỉ khớp tốt với dữ liệu huấn luyện mà còn có khả năng tổng quát hóa cao trên dữ liệu chưa thấy. Về bản chất, SVM là một bộ phân loại tuyến tính tìm kiếm siêu phẳng tối ưu phân tách các lớp dữ liệu trong không gian đặc trưng, sao cho khoảng cách từ siêu phẳng đến các điểm dữ liệu gần nhất của mỗi lớp là lớn nhất có thể. Thông qua kỹ thuật hàm nhân, SVM có thể mở rộng sang các bài toán phi tuyến mà không cần tường minh tính toán trong không gian chiều cao.

Cũng như hồi quy logistic, SVM được thiết kế chủ yếu cho các bài toán phân loại nhị phân, trong đó mục tiêu là phân chia không gian đặc trưng thành hai vùng tương ứng với hai nhãn lớp. Thông qua các phương pháp mở rộng phổ biến như phân loại nhiều lớp với mỗi lớp là một bài toán nhị phân độc lập (One-vs-Rest) hoặc xây dựng các bộ phân loại trên từng cặp lớp (One-vs-One), SVM có thể xử lý hiệu quả các bài toán phân loại đa lớp. Ngoài ra, biến thể hồi quy vector hỗ trợ (Support Vector Regression - SVR) cho phép áp dụng nguyên lý của SVM vào các bài toán hồi quy, mở rộng đáng kể phạm vi ứng dụng của mô hình.

Siêu phẳng, margin và support vectors

Trong không gian n chiều $\mathbb{R}^n$, một siêu phẳng là tập hợp các điểm $\mathbf{x}$ thỏa mãn phương trình tuyến tính:

$$\mathbf{w}^T \mathbf{x} + b = 0 \quad (2.9)$$

trong đó $\mathbf{w} \in \mathbb{R}^n$ là vector pháp tuyến xác định hướng của siêu phẳng và $b \in \mathbb{R}$ là hệ số lệch xác định vị trí của siêu phẳng trong không gian. Siêu phẳng này chia không gian thành hai nửa tương ứng với hai lớp phân loại: lớp dương tính ($y = +1$) khi $\mathbf{w}^T \mathbf{x} + b > 0$ và lớp âm tính ($y = -1$) khi $\mathbf{w}^T \mathbf{x} + b < 0$.

Khoảng cách từ một điểm $\mathbf{x}_i$ đến siêu phẳng được xác định bởi:

$$d_i = \frac{|\mathbf{w}^T \mathbf{x}_i + b|}{\|\mathbf{w}\|} \quad (2.10)$$

Biên độ (*margin*) của siêu phẳng được định nghĩa là tổng khoảng cách từ siêu phẳng đến điểm gần nhất của mỗi lớp. Khi chuẩn hóa sao cho $|\mathbf{w}^T \mathbf{x}_i + b| = 1$ với các điểm gần nhất, biên độ này bằng $\frac{2}{\|\mathbf{w}\|}$. Mục tiêu của SVM là tìm siêu phẳng có biên độ lớn nhất, vì biên độ càng lớn thì mô hình càng ít nhạy cảm với nhiễu và có khả năng tổng quát hóa tốt hơn.

Các vector hỗ trợ (*support vectors*) là những điểm dữ liệu nằm trên biên giới của biên độ, tức là những điểm thỏa mãn $|\mathbf{w}^T \mathbf{x}_i + b| = 1$. Đây là các điểm duy nhất quyết định vị trí và hướng của siêu phẳng tối ưu — nếu loại bỏ các điểm này, siêu phẳng sẽ thay đổi, trong khi loại bỏ các điểm còn lại thì không.

Nguyên lý hoạt động

Ý tưởng cốt lõi của SVM là tìm một ranh giới quyết định phân tách hai lớp dữ liệu sao cho khoảng cách từ ranh giới đó đến các điểm dữ liệu gần nhất của mỗi lớp được tối đa hóa. Bằng cách tìm siêu phẳng tối đa hóa biên độ $\frac{2}{\|\mathbf{w}\|}$ (tương đương với việc tối thiểu hóa $\|\mathbf{w}\|^2$), đồng thời đảm bảo tất cả các điểm dữ liệu được phân loại đúng. Có thể nói, lập luận cơ bản đằng sau nguyên tắc này là: trong số tất cả các siêu phẳng có thể phân tách hai lớp, siêu phẳng có biên độ lớn nhất cung cấp sự phân tách “an toàn” nhất, làm giảm thiểu rủi ro phân loại sai trên dữ liệu mới. Nguyên lý này xuất phát từ lập luận rằng một ranh giới quyết định có biên độ lớn hơn sẽ có độ tin cậy cao hơn và ít nhạy cảm hơn với nhiễu trong dữ liệu, từ đó dẫn đến khả năng tổng quát hóa tốt hơn trên dữ liệu mới.

Vậy nên, quá trình huấn luyện của SVM về bản chất là một bài toán tối ưu hóa lồi, trong đó mô hình tìm kiếm các bộ tham số xác định siêu phẳng tối ưu thông qua phương pháp gradient descent - phương pháp lặp cập nhật tham số theo chiều giảm nhanh nhất của hàm mục tiêu. Vì SVM chỉ phụ thuộc vào một tập con nhỏ là các điểm dữ liệu huấn luyện, hay còn gọi là các vector hỗ trợ để xác định ranh giới quyết định, thay vì toàn bộ tập dữ liệu. Tính chất này mang lại cho SVM sự hiệu quả đặc biệt về mặt bộ nhớ và độ bền trước các điểm dữ liệu ngoại lệ nằm xa ranh giới.

Soft-Margin SVM

Trong thực tế, dữ liệu hiếm khi có thể được phân tách hoàn toàn bằng một siêu phẳng tuyến tính - đặc biệt khi dữ liệu có nhiễu hoặc các lớp có vùng chồng lấp nhau. Để xử lý trường hợp này, SVM được mở rộng thành biến thể soft-margin bằng cách cho phép một số điểm dữ liệu vi phạm ràng buộc phân tách, thay vì yêu cầu tất cả các điểm phải nằm đúng phía và cách xa siêu phẳng ít nhất một khoảng bằng $\frac{1}{\|\mathbf{w}\|}$.

Cụ thể, với mỗi điểm dữ liệu $\mathbf{x}_i$, một biến bù $\xi_i \geq 0$ được đưa vào để đo mức độ vi phạm: $\xi_i = 0$ nghĩa là điểm nằm đúng phía và đủ xa siêu phẳng, $0 < \xi_i \leq 1$ nghĩa là điểm nằm đúng phía nhưng quá gần siêu phẳng, còn $\xi_i > 1$ nghĩa là điểm bị phân loại sai. Bài toán tối ưu hóa lúc này trở thành:

$$\min_{\mathbf{w}, b, \xi} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \quad (2.11)$$

$$\text{ràng buộc} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad \forall i \quad (2.12)$$

Tham số $C > 0$ là siêu tham số điều tiết, kiểm soát sự đánh đổi giữa việc tối đa hóa biên độ và chấp nhận vi phạm phân loại. Khi C lớn, mô hình bị phạt nặng hơn với mỗi vi phạm, do đó ưu tiên phân loại đúng tất cả các điểm huấn luyện nhưng có thể dẫn đến biên độ nhỏ hơn và nguy cơ quá khớp cao hơn. Ngược lại, khi C nhỏ, mô hình chấp nhận nhiều vi phạm hơn để đổi lấy biên độ lớn hơn, giúp mô hình tổng quát hóa tốt hơn trên

dữ liệu mới.

Kernel SVM

Nhiều bài toán phân loại có ranh giới quyết định không thể biểu diễn bằng một siêu phẳng tuyến tính trong không gian đặc trưng gốc. Để giải quyết hạn chế này, SVM được mở rộng thông qua kỹ thuật hàm nhân (kernel), cho phép mô hình học các ranh giới quyết định phi tuyến mà không cần tường minh ánh xạ dữ liệu sang không gian chiều cao.

Ý tưởng cốt lõi của kỹ thuật hàm nhân xuất phát từ quan sát rằng trong bài toán đối ngẫu, dữ liệu chỉ xuất hiện dưới dạng tích vô hướng $\mathbf{x}_i^T \mathbf{x}_j$. Thay vì tường minh tính toán $\phi(\mathbf{x})$, hàm ánh xạ dữ liệu sang không gian chiều cao ta có thể thay thế tích vô hướng bằng một hàm nhân $K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$, cho phép mô hình ngầm định hoạt động trong không gian chiều cao mà không cần tính toán $\phi(\mathbf{x})$ một cách tường minh. Lợi thế của kernel SVM là khả năng học các cấu trúc phi tuyến phức tạp với chi phí tính toán hợp lý.

Trong phạm vi khóa luận này, hàm nhân được sử dụng là hàm nhân cơ sở hướng tâm (Radial Basis Function - RBF) sẽ được sử dụng, đây cũng là hàm nhân phổ biến nhất trong thực tế:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2), \quad \gamma > 0 \quad (2.13)$$

Hàm nhân RBF đo lường sự tương đồng giữa hai điểm dữ liệu dựa trên khoảng cách Euclidean giữa chúng: hai điểm càng gần nhau thì giá trị hàm nhân càng tiệm cận 1 và càng xa nhau thì càng tiệm cận 0. Tham số $\gamma > 0$ kiểm soát phạm vi ảnh hưởng của mỗi điểm dữ liệu: γ lớn làm cho mô hình chỉ chú ý đến các điểm lân cận rất gần, dẫn đến ranh giới quyết định cục bộ và phức tạp hơn; trong khi γ nhỏ tạo ra ranh giới mượt mà hơn và có khả năng tổng quát hóa tốt hơn trên dữ liệu mới.

Hàm mất mát và phương pháp tối ưu

SVM sử dụng hàm mất mát Hinge Loss, được định nghĩa cho từng mẫu như sau:

$$\ell_i = \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)) \quad (2.14)$$

trong đó $y_i \in \{-1, +1\}$ là nhãn thực tế và $\mathbf{w}^T \mathbf{x}_i + b$ là giá trị dự đoán của mô hình trước khi phân loại. Tích $y_i(\mathbf{w}^T \mathbf{x}_i + b)$ đo mức độ tự tin của mô hình: giá trị dương lớn nghĩa là phân loại đúng với độ tự tin cao, giá trị âm nghĩa là phân loại sai.

Hàm này có ý nghĩa trực quan: nếu điểm dữ liệu được phân loại đúng và nằm đủ xa siêu phẳng, mất mát bằng 0, mô hình không bị phạt. Ngược lại, nếu điểm nằm quá gần

hoặc bị phân loại sai, mất mát tăng tuyến tính theo mức độ vi phạm. Nói cách khác, SVM không quan tâm đến việc phân loại đúng đến mức nào, mà chỉ phạt những trường hợp chưa đủ tự tin hoặc sai. Khi hàm mục tiêu tổng thể kết hợp Hinge Loss với thành phần chính quy hóa L2, nó có dạng như sau:

$$\mathcal{L}(\mathbf{w}, b) = \frac{1}{2}\|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)) \quad (2.15)$$

trong đó tham số $C > 0$ kiểm soát sự đánh đổi giữa biên độ lớn và mức độ chấp nhận vi phạm: C lớn nghĩa là mô hình bị phạt nặng hơn khi có điểm bị phân loại sai, do đó cố gắng phân loại đúng tất cả các điểm huấn luyện; C nhỏ nghĩa là mô hình chấp nhận một số vi phạm để đổi lấy biên độ lớn hơn và khả năng tổng quát hóa tốt hơn.

Ưu điểm và ứng dụng thực tế

SVM có một số đặc điểm thuận lợi nổi bật trong các bài toán phân loại. Thứ nhất, nhờ nguyên tắc tối đa hóa biên độ, mô hình có khả năng tổng quát hóa tốt và giảm thiểu rủi ro quá khớp ngay cả trong không gian chiều cao. Thứ hai, thông qua kỹ thuật hàm nhân, SVM có thể xử lý hiệu quả các bài toán phi tuyến phức tạp mà không bị ảnh hưởng bởi lời nguyền chiều cao như các phương pháp khác. Thứ ba, do chỉ phụ thuộc vào các vector hỗ trợ, mô hình hiệu quả về bộ nhớ và bền vững trước các điểm dữ liệu ngoại lệ nằm xa ranh giới quyết định.

Nhờ các đặc điểm trên, SVM được ứng dụng rộng rãi trong nhiều lĩnh vực đòi hỏi độ chính xác cao. Trong y sinh học, mô hình được sử dụng để phân loại dữ liệu gen, chẩn đoán bệnh từ dữ liệu y tế và phân tích tín hiệu não (EEG/fMRI). Trong phân loại văn bản và xử lý ngôn ngữ tự nhiên, SVM với kernel tuyến tính cho kết quả tốt trong không gian đặc trưng thưa chiều cao. Trong tài chính, mô hình được sử dụng cho phát hiện gian lận và dự đoán biến động thị trường.

Hạn chế

Bên cạnh các ưu điểm trên, SVM cũng tồn tại một số hạn chế cần lưu ý. Hạn chế lớn nhất là chi phí tính toán cao khi huấn luyện trên tập dữ liệu lớn: độ phức tạp thời gian của các thuật toán giải bài toán tối ưu thường là $O(m^2)$ đến $O(m^3)$ theo số mẫu m , khiến SVM trở nên kém hiệu quả khi m lên đến hàng triệu. Thứ hai, việc lựa chọn kernel và điều chỉnh các siêu tham số (C, γ) đòi hỏi phải thử nghiệm nhiều tổ hợp giá trị khác nhau và đánh giá hiệu suất từng tổ hợp, làm tăng đáng kể chi phí tính toán tổng thể. Cuối cùng, không giống như hồi quy logistic, SVM không trực tiếp cho ra xác suất mà chỉ cho ra nhãn phân loại. Để có được đầu ra dạng xác suất, cần huấn luyện thêm một mô hình phụ trợ trên đầu ra của SVM, làm tăng thêm chi phí tính toán so với các mô hình vốn đã cho ra xác suất trực tiếp.

2.5.3 Mô hình Random Forest

Khái niệm

Rừng ngẫu nhiên (Random Forest) là một thuật toán học máy có giám sát thuộc lớp các phương pháp học tập kết hợp (ensemble learning), được xây dựng bằng cách kết hợp một tập hợp lớn các cây quyết định được huấn luyện độc lập trên các tập con dữ liệu ngẫu nhiên khác nhau. Kết quả dự đoán cuối cùng được tổng hợp từ tất cả các cây thành phần thông qua cơ chế biểu quyết đa số trong bài toán phân loại, hoặc lấy trung bình trong bài toán hồi quy. Tên gọi "rừng ngẫu nhiên" phản ánh hai yếu tố cốt lõi: "rừng" biểu thị tập hợp nhiều cây quyết định, và "ngẫu nhiên" biểu thị hai nguồn ngẫu nhiên hóa được đưa vào, lấy mẫu tập dữ liệu có thay thế và lựa chọn ngẫu nhiên tập con đặc trưng tại mỗi nút phân chia.

Về mặt hình thức, cho tập huấn luyện $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$ gồm m mẫu, Random Forest xây dựng một tập hợp B cây quyết định $\{T_1, T_2, \dots, T_B\}$, trong đó mỗi cây T_b được huấn luyện trên tập bootstrap $\mathcal{D}_b$, tức là tập dữ liệu được lấy mẫu có thay thế từ $\mathcal{D}$ với cùng kích thước m và sử dụng ngẫu nhiên một tập con gồm k đặc trưng tại mỗi nút phân chia thay vì toàn bộ đặc trưng. Ở đây $\mathbf{x}_i \in \mathbb{R}^n$ là vector đặc trưng và y_i là nhãn lớp của mẫu thứ i . Dự đoán cuối cùng là hàm tổng hợp trên toàn bộ B cây.

Thuật toán Random Forest được Leo Breiman công bố chính thức vào năm 2001, tổng hợp và hệ thống hóa các ý tưởng từ nhiều công trình trước đó. Kỹ thuật lấy mẫu có thay thế để giảm phương sai của mô hình được đề xuất bởi Breiman từ năm 1996, trong khi kỹ thuật lựa chọn ngẫu nhiên tập con đặc trưng tại mỗi nút phân chia được nghiên cứu bởi Ho (1995) và Amit và Geman (1997). Breiman chứng minh rằng hiệu suất tổng quát hóa của Random Forest phụ thuộc vào độ mạnh trung bình của các cây thành phần và sự tương quan giữa chúng - đặt nền tảng lý thuyết cho nguyên tắc thiết kế: tối đa hóa độ mạnh của từng cây trong khi tối thiểu hóa sự tương quan giữa các cây.

Trong thực tế, Random Forest được thiết kế để giải quyết cả hai nhóm bài toán học máy có giám sát chính là phân loại (classification) và hồi quy (regression). Tuy nhiên, mục tiêu sâu xa hơn của thuật toán là khắc phục các hạn chế cơ bản của Decision Tree đơn lẻ, đặc biệt là tính không ổn định và xu hướng học vẹt, bằng việc kết hợp nhiều mô hình yếu thành một mô hình tổng hợp mạnh và ổn định hơn. Ngoài hai ứng dụng phân loại và hồi quy, Random Forest còn được sử dụng rộng rãi như một công cụ đánh giá tầm quan trọng đặc trưng (kỹ thuật lựa chọn đặc trưng được nhắc đến tại ??), hỗ trợ lựa chọn đặc trưng trong các quy trình tiền xử lý dữ liệu phức tạp.

Nguyên lý hoạt động

Ý tưởng cốt lõi của Random Forest là xây dựng nhiều cây quyết định độc lập, mỗi cây được huấn luyện trên một phiên bản ngẫu nhiên khác nhau của tập dữ liệu, sau đó tổng hợp kết quả từ tất cả các cây để đưa ra dự đoán cuối cùng. Sự kết hợp này giúp khắc

phục hạn chế cơ bản của cây quyết định đơn lẻ, vốn có xu hướng quá khớp với dữ liệu huấn luyện bằng cách trung hòa các sai lệch ngẫu nhiên của từng cây.

Quá trình huấn luyện mỗi cây T_b gồm hai bước ngẫu nhiên hóa. Thứ nhất, thay vì huấn luyện trên toàn bộ tập dữ liệu $\mathcal{D}$, mỗi cây được huấn luyện trên một tập con $\mathcal{D}_b$ được lấy mẫu có thay thế từ $\mathcal{D}$ với cùng kích thước m , tức là một số mẫu có thể được chọn nhiều lần trong khi một số khác không được chọn. Thứ hai, tại mỗi nút phân chia, thay vì xem xét toàn bộ n đặc trưng, mô hình chỉ xem xét một tập con gồm k đặc trưng được chọn ngẫu nhiên, thường lấy $k = \sqrt{n}$ cho bài toán phân loại. Hai nguồn ngẫu nhiên hóa này đảm bảo các cây trong rừng đủ khác biệt nhau, tránh trường hợp tất cả các cây đều mắc cùng một loại sai lầm. Sau khi huấn luyện B cây, dự đoán cuối cùng cho một mẫu mới $\mathbf{x}$ được tổng hợp bằng cơ chế biểu quyết đa số:

$$\hat{y} = \arg \max_c \sum_{b=1}^B \mathbf{1}[T_b(\mathbf{x}) = c] \quad (2.16)$$

trong đó $T_b(\mathbf{x})$ là nhãn dự đoán của cây thứ b cho mẫu $\mathbf{x}$, c là nhãn lớp, và $\mathbf{1}[\cdot]$ là hàm chỉ thị nhận giá trị 1 nếu điều kiện đúng và 0 nếu sai. Nói cách khác, nhãn được dự đoán bởi nhiều cây nhất sẽ là kết quả cuối cùng.

Các siêu tham số

Siêu tham số là các tham số được thiết lập trước khi huấn luyện mô hình và không được học từ dữ liệu, khác với các tham số như trọng số $\mathbf{w}$ được tối ưu hóa trong quá trình huấn luyện. Việc lựa chọn siêu tham số phù hợp ảnh hưởng trực tiếp đến hiệu suất và khả năng tổng quát hóa của mô hình. Trong phạm vi khóa luận, hai siêu tham số chính của Random Forest được điều chỉnh. Thứ nhất là số lượng cây B (`n_estimators`), kiểm soát độ ổn định của mô hình: B càng lớn thì dự đoán càng ổn định do trung hòa được nhiều sai lệch ngẫu nhiên hơn, nhưng chi phí tính toán cũng tăng tương ứng. Thứ hai là chiều sâu tối đa của mỗi cây (`max_depth`), kiểm soát mức độ phức tạp của từng cây thành phần: cây càng sâu thì càng có khả năng học các cấu trúc phức tạp trong dữ liệu, nhưng cũng dễ quá khớp hơn. Khi `max_depth = None`, tức không dùng đến `max_depth`, cây được phép phát triển đến khi tất cả các lá thuần nhất hoàn toàn.

Ưu điểm và ứng dụng thực tế

Random Forest có một số đặc điểm thuận lợi khiến mô hình này được sử dụng rộng rãi. Thứ nhất, nhờ cơ chế kết hợp nhiều cây độc lập, mô hình có khả năng tổng quát hóa tốt và ít nhạy cảm với nhiễu trong dữ liệu so với cây quyết định đơn lẻ. Thứ hai, mô hình hoạt động hiệu quả trên cả dữ liệu chiều cao lẫn dữ liệu có nhiều đặc trưng không liên quan, nhờ cơ chế lựa chọn ngẫu nhiên đặc trưng tại mỗi nút phân chia. Thứ ba, quá trình huấn luyện các cây độc lập có thể thực hiện song song, giúp giảm đáng kể thời gian tính toán trên các hệ thống đa nhân. Nhờ các đặc điểm trên, Random Forest được ứng dụng

rộng rãi trong y sinh học để phân loại dữ liệu gen và chẩn đoán bệnh, trong tài chính để phát hiện gian lận và đánh giá rủi ro tín dụng, cũng như trong các bài toán phân loại hình ảnh và xử lý ngôn ngữ tự nhiên.

Hạn chế

Bên cạnh các ưu điểm trên, Random Forest cũng tồn tại một số hạn chế cần lưu ý. Thứ nhất, do kết hợp hàng trăm cây quyết định, mô hình mất đi tính diễn giải trực quan vốn có của cây quyết định đơn lẻ, khó giải thích tại sao mô hình đưa ra một dự đoán cụ thể. Thứ hai, chi phí bộ nhớ và thời gian dự đoán tăng tuyến tính theo số lượng cây B , có thể trở thành hạn chế trong các hệ thống yêu cầu phản hồi thời gian thực. Cuối cùng, trên các tập dữ liệu có mất cân bằng lớp nghiêm trọng, mô hình có xu hướng thiên lệch về phía lớp đa số nếu không áp dụng các kỹ thuật bổ trợ phù hợp.

2.5.4 XGBoost (Extreme Gradient Boosting)

2.5.5 MLP (Multilayer Perceptron)

Perceptron đa tầng (Multilayer Perceptron - MLP) là một trong những kiến trúc mạng nơ-ron nhân tạo nền tảng và phổ biến nhất trong học máy hiện đại. Lấy cảm hứng từ cách thức hoạt động của hệ thần kinh sinh học, MLP mô phỏng quá trình truyền và xử lý thông tin qua các lớp tế bào nơ-ron nhân tạo được kết nối với nhau theo cấu trúc phân tầng. Mỗi đơn vị tính toán trong mạng tương tự một tế bào thần kinh, chúng nhận tín hiệu từ các đơn vị ở tầng trước, thực hiện một phép biến đổi có trọng số, sau đó truyền kết quả đến tầng tiếp theo.

Điểm then chốt phân biệt MLP so với các mô hình tuyến tính truyền thống nằm ở khả năng học các biểu diễn phi tuyến phức tạp trực tiếp từ dữ liệu. Trong khi các phương pháp như hồi quy logistic hay máy vector hỗ trợ tuyến tính (SVM) giả định rằng ranh giới quyết định có thể được xấp xỉ bằng một hàm tuyến tính của các đặc trưng đầu vào, MLP không đặt ra ràng buộc này. Thông qua việc xếp chồng nhiều tầng biến đổi phi tuyến, mô hình có thể học và biểu diễn các mẫu tương tác phức tạp giữa các đặc trưng mà không cần thiết kế thủ công bởi chuyên gia lĩnh vực. Tính chất này làm cho MLP trở thành một lựa chọn đặc biệt phù hợp cho các bài toán phân loại dữ liệu y tế, nơi mối quan hệ giữa các chỉ số lâm sàng và kết quả bệnh thường mang bản chất phi tuyến và phức tạp.

Kiến trúc cơ bản

Một mạng MLP điển hình được tổ chức thành ba loại tầng chức năng chính, mỗi tầng đóng vai trò xác định trong luồng xử lý thông tin của mô hình.

Tầng đầu vào (input layer) là tầng đầu tiên, có nhiệm vụ tiếp nhận dữ liệu thô từ bên ngoài. Số lượng đơn vị trong tầng này bằng đúng số chiều của vector đặc trưng đầu vào, tức là số lượng biến quan sát cho mỗi mẫu dữ liệu. Tầng đầu vào không thực hiện

bất kỳ phép biến đổi nào mà đơn giản chuyển tiếp giá trị của từng đặc trưng đến tầng tiếp theo. Trong bối cảnh dữ liệu y tế, mỗi đơn vị đầu vào tương ứng với một chỉ số lâm sàng như huyết áp, nồng độ glucose, chỉ số khối cơ thể hay kết quả xét nghiệm máu.

Các tầng ẩn (hidden layers) là các tầng nằm giữa tầng đầu vào và tầng đầu ra, và là nơi phần lớn quá trình học biểu diễn diễn ra. Mỗi đơn vị trong tầng ẩn tính toán một tổ hợp có trọng số của tất cả đầu ra từ tầng trước đó, sau đó áp dụng một hàm phi tuyến lên kết quả. Qua nhiều tầng ẩn xếp chồng, mô hình dần dần xây dựng các biểu diễn trừu tượng hơn của dữ liệu đầu vào, từ các đặc trưng cơ bản ở tầng đầu đến các tổ hợp đặc trưng bậc cao phản ánh các mẫu phức tạp ở các tầng sâu hơn. Số lượng tầng ẩn và số đơn vị trong mỗi tầng là các siêu tham số kiến trúc ảnh hưởng trực tiếp đến khả năng biểu diễn và mức độ phức tạp của mô hình.

Tầng đầu ra (output layer) là tầng cuối cùng, chuyển đổi biểu diễn học được từ các tầng ẩn thành dạng phù hợp với bài toán cụ thể. Đối với bài toán phân loại nhị phân như chẩn đoán bệnh (có/không), tầng đầu ra thường có một đơn vị duy nhất với hàm kích hoạt sigmoid, trả về xác suất thuộc về lớp dương tính. Đối với phân loại đa lớp, tầng đầu ra có số đơn vị bằng số lớp, với hàm kích hoạt softmax đảm bảo tổng xác suất của tất cả các lớp bằng một.

Học biểu diễn phi tuyến: Trọng số, bias và hàm kích hoạt

Khả năng học biểu diễn phi tuyến của MLP được tạo ra bởi sự kết hợp của ba thành phần cơ bản: trọng số liên kết, hệ số chệch và hàm kích hoạt. Mỗi kết nối giữa một đơn vị ở tầng trước và một đơn vị ở tầng sau được gắn với một giá trị trọng số w , biểu thị mức độ ảnh hưởng của tín hiệu đầu vào tương ứng. Ngoài ra, mỗi đơn vị trong mạng còn có một hệ số chệch b , hằng số cộng thêm trước khi áp dụng hàm kích hoạt cho phép mô hình dịch chuyển hàm kích hoạt, tăng tính linh hoạt trong việc khớp với dữ liệu. Khi được khởi tạo ngẫu nhiên và cập nhật trong quá trình huấn luyện, trọng số và hệ số chệch là các tham số mà mô hình học được từ dữ liệu.

Nếu chỉ dùng tổ hợp tuyến tính của các đầu vào, dù xếp chồng bao nhiêu tầng, mô hình cũng chỉ biểu diễn được các quan hệ tuyến tính vì tổ hợp tuyến tính của tổ hợp tuyến tính vẫn là tuyến tính. Hàm kích hoạt giải quyết vấn đề này bằng cách đưa vào tính phi tuyến sau mỗi lớp tổ hợp tuyến tính, cho phép mạng xấp xỉ bất kỳ hàm liên tục nào với độ chính xác tùy ý khi có đủ đơn vị ẩn — tính chất được gọi là định lý xấp xỉ toàn năng (Cybenko, 1989; Hornik, 1991).

Nguyên lý hoạt động

Phép tính toán tại một đơn vị nơ-ron đơn lẻ diễn ra theo hai bước tuần tự. Đầu tiên, đơn vị tính tổ hợp tuyến tính của tất cả đầu vào mà nó nhận được:

$$z = \sum_{i=1}^n w_i x_i + b = \mathbf{w}^T \mathbf{x} + b \quad (2.12)$$

trong đó x_i là giá trị của đầu vào thứ i đến từ tầng trước (có thể là giá trị đặc trưng

gốc nếu đây là tầng ẩn đầu tiên, hoặc đầu ra của đơn vị ở tầng ẩn trước), w_i là trọng số tương ứng với kết nối từ đầu vào x_i đến đơn vị hiện tại, b là hệ số chệch của đơn vị này, n là tổng số đầu vào mà đơn vị nhận được, và z là giá trị tổng hợp chưa qua kích hoạt. Viết dưới dạng ma trận, $\mathbf{w}^T \mathbf{x}$ là tích vô hướng giữa vector trọng số $\mathbf{w} \in \mathbb{R}^n$ và vector đầu vào $\mathbf{x} \in \mathbb{R}^n$.

Bước thứ hai, giá trị z được đưa qua hàm kích hoạt $\varphi(\cdot)$ để tạo ra đầu ra của đơn vị:

$$a = \varphi(z) = \varphi(\mathbf{w}^T \mathbf{x} + b) \quad (2.13)$$

trong đó a là đầu ra của đơn vị nơ-ron, sẽ được truyền đến tất cả các đơn vị ở tầng tiếp theo. Tổng quát hóa lên toàn bộ một tầng ẩn gồm m đơn vị, lan truyền tiến từ tầng $l-1$ sang tầng l được biểu diễn dưới dạng ma trận:

$$\mathbf{a}^{(l)} = \varphi(\mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}) \quad (2.14)$$

trong đó $\mathbf{W}^{(l)} \in \mathbb{R}^{m_l \times m_{l-1}}$ là ma trận trọng số của tầng l với m_l là số đơn vị ở tầng l và m_{l-1} là số đơn vị ở tầng $l-1$; $\mathbf{b}^{(l)} \in \mathbb{R}^{m_l}$ là vector hệ số chệch; $\mathbf{a}^{(l-1)}$ là vector đầu ra từ tầng trước; và $\varphi(\cdot)$ được áp dụng theo từng phần tử của vector. Phép tính này được lặp lại từ tầng đầu vào qua tất cả các tầng ẩn cho đến tầng đầu ra.

Vai trò của hàm kích hoạt

Hàm kích hoạt là thành phần quyết định tính phi tuyến của mạng. Nếu không có hàm kích hoạt, dù xếp chồng bao nhiêu tầng, toàn bộ mạng vẫn chỉ tương đương một phép biến đổi tuyến tính. Ba hàm kích hoạt được sử dụng phổ biến nhất trong kiến trúc MLP hiện đại là ReLU, sigmoid và softmax, mỗi hàm phù hợp với một vị trí và mục đích cụ thể trong mạng.

Hàm đơn vị tuyến tính có giới hạn dưới (Rectified Linear Unit - ReLU) được định nghĩa là:

$$\varphi_{\text{ReLU}}(z) = \max(0, z) \quad (2.15)$$

trong đó z là giá trị tổng hợp tuyến tính nhận được từ tầng trước, tức là đầu vào chưa qua kích hoạt của một đơn vị nơ-ron. Hàm này hoạt động theo nguyên tắc đơn giản: giữ nguyên giá trị nếu $z > 0$, và trả về không nếu $z \leq 0$. Về mặt đạo hàm, $\varphi'_{\text{ReLU}}(z) = 1$ khi $z > 0$ và bằng không khi $z < 0$, nghĩa là gradient được truyền nguyên vẹn qua các nơ-ron đang hoạt động thay vì bị nén về không như ở các hàm kích hoạt cổ điển. Tính chất này giúp tránh hiện tượng suy giảm gradient, làm cho quá trình huấn luyện mạng sâu trở nên ổn định và hiệu quả hơn. Nhờ đó, ReLU là lựa chọn mặc định cho các tầng ẩn trong hầu hết các kiến trúc mạng nơ-ron hiện đại.

Hàm softmax là tổng quát hóa của hàm sigmoid cho bài toán phân loại đa lớp. Với vector đầu vào $\mathbf{z} = (z_1, z_2, \dots, z_K)$ là đầu ra tuyến tính của tầng cuối cùng, đầu ra softmax tại vị trí k được tính là:

$$\varphi_{\text{softmax}}(z_k) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad k = 1, \dots, K \quad (2.16)$$

trong đó K là tổng số lớp, z_k là giá trị logit tương ứng với lớp k , và mẫu số $\sum_{j=1}^K e^{z_j}$ là tổng của tất cả các giá trị mũ nhằm mục đích chuẩn hóa. Phép chuẩn hóa này đảm bảo hai tính chất quan trọng: mọi đầu ra đều dương, và tổng tất cả đầu ra bằng một, tức là tạo thành một phân phối xác suất hợp lệ trên K lớp. Lớp có giá trị $\varphi_{\text{softmax}}(z_k)$ lớn nhất được chọn làm nhãn dự đoán cuối cùng. Trong khóa luận này, softmax được sử dụng tại tầng đầu ra của MLP cho cả hai bài toán phân loại đa lớp.

Vai trò của hàm kích hoạt

Hàm kích hoạt là thành phần quyết định tính phi tuyến của mạng và ảnh hưởng trực tiếp đến hiệu quả của quá trình huấn luyện. Trong lịch sử phát triển của mạng nơ-ron, nhiều hàm kích hoạt khác nhau đã được đề xuất và sử dụng, mỗi hàm có đặc tính phù hợp với các ngữ cảnh khác nhau trong kiến trúc mạng.

Hàm đơn vị tuyến tính có giới chặn dưới (*Rectified Linear Unit* — ReLU) là hàm kích hoạt phổ biến nhất cho các tầng ẩn trong các mạng nơ-ron hiện đại, được định nghĩa là:

$$\varphi_{\text{ReLU}}(z) = \max(0, z) \quad (2.17)$$

Hàm này giữ nguyên giá trị dương và đưa mọi giá trị âm về không. Sự đơn giản về mặt tính toán của ReLU — đạo hàm bằng một khi $z > 0$ và bằng không khi $z < 0$ — giúp tránh được hiện tượng suy giảm gradient (*vanishing gradient*) thường gặp với các hàm kích hoạt cổ điển hơn, làm cho quá trình huấn luyện mạng sâu trở nên ổn định và hiệu quả hơn đáng kể.

Hàm sigmoid ép mọi giá trị thực vào khoảng $(0, 1)$:

$$\varphi_{\text{sigmoid}}(z) = \frac{1}{1 + e^{-z}} \quad (2.18)$$

Nhờ miền giá trị nằm trong $(0, 1)$, đầu ra của hàm sigmoid có thể được diễn giải tự nhiên như xác suất. Do đó, hàm sigmoid thường được sử dụng tại đơn vị đầu ra duy nhất trong bài toán phân loại nhị phân — chẳng hạn, xác suất một bệnh nhân mắc bệnh tiểu đường hay không.

Hàm softmax là tổng quát hóa của hàm sigmoid cho bài toán phân loại đa lớp. Với vector đầu vào $\mathbf{z} = (z_1, z_2, \dots, z_K)$, đầu ra của softmax tại vị trí k là:

$$\varphi_{\text{softmax}}(z_k) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad k = 1, \dots, K \quad (2.19)$$

trong đó K là tổng số lớp, và đầu ra $\varphi_{\text{softmax}}(z_k)$ là xác suất ước lượng của mẫu thuộc lớp k . Hàm softmax đảm bảo hai tính chất quan trọng: mọi đầu ra đều dương, và tổng tất cả đầu ra bằng một, tức là tạo thành một phân phối xác suất hợp lệ trên K lớp.

Quá trình huấn luyện

Huấn luyện MLP là quá trình tìm bộ trọng số và hệ số chệch sao cho mô hình đưa ra dự đoán gần nhất với nhãn thực tế trên tập dữ liệu huấn luyện. Quá trình này diễn ra qua ba giai đoạn liên tiếp, được lặp lại nhiều lần cho đến khi mô hình hội tụ: lan truyền tiến, tính hàm mất mát, và lan truyền ngược.

Lan truyền tiến

Lan truyền tiến là quá trình tính toán đầu ra của mạng cho một mẫu đầu vào $\mathbf{x}$. Bắt đầu từ tầng đầu vào, tín hiệu được truyền lần lượt qua từng tầng theo công thức:

$$\mathbf{a}^{(l)} = \varphi(\mathbf{W}^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}) \quad (2.20)$$

trong đó $\mathbf{W}^{(l)} \in \mathbb{R}^{m_l \times m_{l-1}}$ là ma trận trọng số của tầng l , với m_l và m_{l-1} lần lượt là số đơn vị ở tầng l và tầng $l-1$; $\mathbf{b}^{(l)} \in \mathbb{R}^{m_l}$ là vector hệ số chệch; $\mathbf{a}^{(l-1)}$ là vector đầu ra từ tầng trước, với $\mathbf{a}^{(0)} = \mathbf{x}$ là vector đặc trưng đầu vào; và $\varphi(\cdot)$ là hàm kích hoạt được áp dụng theo từng phần tử. Phép tính này được lặp lại từ tầng đầu vào qua tất cả các tầng ẩn cho đến tầng đầu ra, nơi mô hình tạo ra dự đoán $\hat{y}$.

Hàm mất mát

Sau khi có dự đoán $\hat{y}$, sai lệch giữa dự đoán và nhãn thực tế y được đo bằng hàm mất mát. Đối với bài toán phân loại nhị phân, hàm mất mát thường dùng là entropy chéo nhị phân, được định nghĩa là:

$$\mathcal{L}(y, \hat{y}) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})] \quad (2.21)$$

trong đó $y \in \{0, 1\}$ là nhãn thực tế và $\hat{y} \in (0, 1)$ là xác suất dự đoán mẫu thuộc lớp dương tính. Hàm mất mát này phạt nặng các dự đoán tự tin nhưng sai: khi $y = 1$ mà $\hat{y}$ gần 0, mất mát tiến đến vô cùng; ngược lại, mất mát tiến về không khi dự đoán đúng với độ tự tin cao. Trên toàn bộ tập dữ liệu gồm n mẫu, mất mát tổng được lấy trung bình:

$$\mathcal{L}_{\text{total}} = \frac{1}{n} \sum_{i=1}^n \mathcal{L}(y_i, \hat{y}_i) \quad (2.22)$$

Lan truyền ngược

Để cập nhật tham số nhằm giảm mất mát, mô hình cần tính đạo hàm của hàm mất mát theo từng tham số. Lan truyền ngược là thuật toán tính hiệu quả các đạo hàm này bằng cách áp dụng quy tắc dây chuyền của vi phân, truyền ngược từ tầng đầu ra về tầng đầu vào. Tại tầng l , gradient của hàm mất mát theo ma trận trọng số được tính là:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} = \boldsymbol{\delta}^{(l)} \cdot (\mathbf{a}^{(l-1)})^T \quad (2.23)$$

trong đó $\boldsymbol{\delta}^{(l)}$ là vector tín hiệu lỗi ngược tại tầng l , được tính đệ quy từ gradient tại tầng $l+1$:

$$\boldsymbol{\delta}^{(l)} = (\mathbf{W}^{(l+1)})^T \boldsymbol{\delta}^{(l+1)} \odot \varphi'(\mathbf{z}^{(l)}) \quad (2.24)$$

trong đó $\odot$ là phép nhân theo từng phần tử (Hadamard), $\mathbf{z}^{(l)} = \mathbf{W}^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}$ là giá trị tổng hợp tuyến tính trước kích hoạt tại tầng l , và $\varphi'(\cdot)$ là đạo hàm của hàm kích hoạt. Chuỗi tính toán đệ quy này cho phép truyền ngược lỗi từ tầng đầu ra qua tất cả các tầng ẩn chỉ trong một lần duyệt, đảm bảo hiệu quả tính toán ngay cả với mạng rất sâu.

Tối ưu hóa bằng hạ gradient

Sau khi có gradient, các tham số được cập nhật theo hướng giảm mất mát. Quy tắc cập nhật cơ bản theo phương pháp hạ gradient ngẫu nhiên là:

$$\mathbf{W}^{(l)} \leftarrow \mathbf{W}^{(l)} - \eta \cdot \frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} \quad (2.25)$$

trong đó $\eta > 0$ là tốc độ học, kiểm soát kích thước bước di chuyển trong không gian tham số mỗi lần cập nhật. Trong thực tế, thuật toán Adam thường được ưa dùng hơn SGD thuần túy, do Adam kết hợp động lượng và tốc độ học thích nghi cho từng tham số, giúp hội tụ nhanh hơn và ổn định hơn trên nhiều loại bài toán. Toàn bộ chu kỳ lan truyền tiến $\rightarrow$ tính mất mát $\rightarrow$ lan truyền ngược $\rightarrow$ cập nhật tham số được lặp lại nhiều lần trên toàn bộ tập huấn luyện cho đến khi mất mát hội tụ về một giá trị đủ nhỏ hoặc hiệu năng trên tập kiểm định không còn cải thiện.

Ưu điểm của MLP trong bài toán dữ liệu y tế

Đối với bài toán phân loại dữ liệu chăm sóc sức khỏe, MLP mang lại một số ưu điểm quan trọng so với các mô hình truyền thống. Trước hết, dữ liệu y tế thường chứa đựng các mối quan hệ phi tuyến phức tạp giữa các chỉ số lâm sàng và kết quả bệnh: ví dụ, tác động của nồng độ glucose máu đến nguy cơ mắc tiểu đường không phải là tuyến tính đơn giản mà có sự tương tác với các yếu tố khác như chỉ số khối cơ thể và tuổi tác. MLP có khả năng tự động phát hiện và mô hình hóa các mối quan hệ và tương tác đặc trưng bậc cao này mà không cần chuyên gia phải thiết kế thủ công, nhờ vào chuỗi biến đổi phi tuyến qua các tầng ẩn.

Thứ hai, MLP không đặt ra các giả định phân phối về dữ liệu đầu vào, không yêu cầu phân phối chuẩn, không cần tính độc lập giữa các đặc trưng, điều này đặc biệt có giá trị trong dữ liệu y tế thực tế vốn thường không thỏa mãn các giả định thống kê lý tưởng. Thứ ba, MLP có khả năng mở rộng tự nhiên sang bài toán phân loại đa lớp thông qua tầng đầu ra với hàm softmax, phù hợp cho các bài toán phân loại nhiều mức độ bệnh. Cuối cùng, với kích thước mạng phù hợp, MLP có khả năng biểu diễn các hàm quyết định rất phức tạp, tiệm cận khả năng của các kiến trúc học sâu hiện đại trong khi vẫn duy trì được sự đơn giản về mặt huấn luyện và triển khai.

Hạn chế

Mặc dù có nhiều ưu điểm, MLP cũng đặt ra một số thách thức cần được xem xét cẩn thận trong thực tế.

Xu hướng quá khớp dữ liệu huấn luyện: Với số lượng tham số lớn, một mạng MLP vừa có thể có hàng nghìn đến hàng triệu tham số khiến mô hình dễ “ghi nhớ” chi tiết và nhiễu của tập huấn luyện thay vì học các mẫu tổng quát, dẫn đến hiệu năng kém trên dữ liệu mới. Các kỹ thuật như *dropout* (tắt ngẫu nhiên một tỉ lệ nơ-ron trong mỗi bước huấn luyện), chính quy hóa L2 trên trọng số và dừng sớm khi hiệu năng kiểm định không còn cải thiện là các biện pháp kiểm soát quá khớp được sử dụng rộng rãi. Thách thức này càng trở nên nổi bật hơn khi tập dữ liệu y tế thường có kích thước hạn chế so với số lượng đặc trưng.

Phụ thuộc vào chuẩn hóa dữ liệu: khác với cây quyết định hay rừng ngẫu nhiên, các phương pháp chỉ sử dụng thứ tự và ngưỡng của giá trị đặc trưng, MLP thực hiện các phép nhân và cộng trực tiếp trên giá trị số. Điều này làm cho mô hình rất nhạy cảm với phạm vi giá trị của các đặc trưng: nếu một đặc trưng có giá trị trong khoảng $[0, 1000]$ trong khi đặc trưng khác có giá trị trong $[0, 1]$, các trọng số liên kết với đặc trưng thứ nhất sẽ có xu hướng chi phối quá mức quá trình học, làm lệch gradient và cản trở hội tụ. Do đó, chuẩn hóa dữ liệu đầu vào, thường là chuẩn hóa về phạm vi $[0, 1]$ hoặc về phân phối có trung bình bằng không và độ lệch chuẩn bằng một là bước tiền xử lý bắt buộc trước khi huấn luyện MLP.

Số lượng siêu tham số lớn và nhạy cảm: hiệu năng của MLP phụ thuộc vào nhiều quyết định thiết kế: số tầng ẩn, số đơn vị trong mỗi tầng, loại hàm kích hoạt, tốc độ học, kích thước batch, tỉ lệ dropout, và các hệ số chính quy hóa. Không có một bộ siêu tham số tối ưu nào phù hợp với mọi bài toán, và quá trình tìm kiếm siêu tham số tốt, thường thông qua tìm kiếm lưới hoặc tìm kiếm ngẫu nhiên kết hợp kiểm định chéo, đòi hỏi thời gian và tài nguyên tính toán đáng kể.

Khó diễn giải kết quả: không giống như hồi quy logistic, nơi hệ số của từng biến trực tiếp phản ánh ảnh hưởng của biến đó lên kết quả hay cây quyết định có thể được đọc như tập quy tắc rõ ràng, MLP là một “hộp đen” về mặt diễn giải. Với hàng nghìn tham số phân tán qua nhiều tầng, việc trả lời câu hỏi "tại sao mô hình đưa ra dự đoán này cho bệnh nhân cụ thể đó?" đòi hỏi các kỹ thuật diễn giải bổ sung như SHAP values hay LIME. Hạn chế này có thể là rào cản đáng kể trong các ứng dụng y tế, nơi tính minh bạch và khả năng giải thích của quyết định lâm sàng là yêu cầu quan trọng.

Chương 3

PHƯƠNG PHÁP NGHIÊN CỨU

Chương này trình bày toàn bộ quy trình thực nghiệm được xây dựng để giải quyết các vấn đề đặc thù của hai bộ dữ liệu y tế. Khác với các nghiên cứu áp dụng một pipeline duy nhất cho mọi bộ dữ liệu, đề tài thiết kế hai pipeline độc lập, mỗi pipeline được tối ưu hóa cho đặc tính chủ đạo của từng bộ dữ liệu: Pipeline Breast Cancer tập trung vào xử lý số chiều cao và phân tích tính phi tuyến; Pipeline Diabetes tập trung vào xử lý mất cân bằng lớp. Tính phi tuyến được khảo sát xuyên suốt cả hai pipeline thông qua trực quan hóa và phân tích tầm quan trọng đặc trưng (*feature importance*), đóng vai trò là một góc phân tích định tính để giải thích kết quả định lượng.

Toàn bộ thực nghiệm được triển khai bằng Python 3.10 với các thư viện: *scikit-learn* (mô hình phân loại, feature selection, đánh giá), *XGBoost*, *imbalanced-learn* (SMOTE, SMOTE+ENN), *UMAP-learn*, *matplotlib* và *seaborn*. Mã nguồn được tổ chức theo cấu trúc module hóa để đảm bảo tái sử dụng giữa hai pipeline.

3.1 Thiết lập thực nghiệm chung

Phần này mô tả các quyết định thiết kế được áp dụng thống nhất trên cả hai pipeline nhằm đảm bảo tính công bằng và khả năng so sánh trong đánh giá mô hình.

3.1.1. Phân chia dữ liệu

Mỗi bộ dữ liệu được phân chia thành tập huấn luyện (*train*) và tập kiểm tra (*test*) theo tỉ lệ 80/20 bằng phương pháp *Stratified Sampling* — đảm bảo tỉ lệ các lớp trong tập train và tập test phản ánh đúng phân phối của toàn bộ dữ liệu gốc. Điều này đặc biệt quan trọng với bộ dữ liệu Diabetes có mất cân bằng lớp rõ rệt: nếu không phân tầng, tập test có thể tình cờ chứa quá ít hoặc quá nhiều mẫu của lớp thiểu số, dẫn đến ước lượng hiệu năng không đáng tin cậy.

Nguyên tắc “không rò rỉ dữ liệu” (*no data leakage*) được tuân thủ nghiêm ngặt: tất cả các bước ước lượng tham số — bao gồm *fit* của **StandardScaler**, *fit* của **Variance Threshold**, *fit* của **SelectKBest**, *fit* của **RFECV** và *fit* của **SMOTE/SMOTE+ENN** — chỉ được thực hiện trên tập train. Các tham số này sau đó được áp dụng (*transform*) lên tập

test mà không có bất kỳ sự điều chỉnh nào. Vì phạm nguyên tắc này sẽ làm cho đánh giá trên tập test không còn phản ánh hiệu năng thực sự của mô hình trên dữ liệu chưa thấy.

3.1.2. Kiểm định chéo và tối ưu siêu tham số

Stratified K-Fold Cross-Validation với $k = 5$ được sử dụng trong giai đoạn huấn luyện để ước lượng hiệu năng mô hình một cách ổn định và giảm thiểu phương sai do sự phân chia ngẫu nhiên. Với $k = 5$, mỗi mô hình được huấn luyện và đánh giá 5 lần trên các phân vùng khác nhau của tập train; kết quả trung bình và độ lệch chuẩn giữa các fold phản ánh độ ổn định của mô hình.

`GridSearchCV` kết hợp *Stratified K-Fold* được sử dụng để tìm kiếm bộ siêu tham số tối ưu trong không gian tìm kiếm được định nghĩa trước. Tiêu chí tối ưu hóa là F1-score macro (trung bình F1 trên tất cả các lớp, không trọng số) cho cả hai pipeline — phù hợp với mục tiêu đánh giá toàn diện trên mọi lớp, đặc biệt các lớp thiểu số. Bảng 3.1 trình bày không gian tìm kiếm siêu tham số cho từng mô hình.

Bảng 3.1: Không gian tìm kiếm siêu tham số của các mô hình.

Mô hình	Siêu tham số	Không gian tìm kiếm
Logistic Regression	C (regularization)	{0.001, 0.01, 0.1, 1, 10, 100}
SVM (RBF)	C ; γ	$C \in \{0.1, 1, 10, 100\}$; $\gamma \in \{\text{scale}, \text{auto}, 0.001, 0.01\}$
Decision Tree	<code>max_depth</code> ; <code>min_samples_split</code>	<code>max_depth</code> $\in \{5, 10, 20, \text{None}\}$; <code>min_samples_split</code> $\in \{2, 5, 10\}$
KNN	<code>n_neighbors</code> ; <code>metric</code>	<code>n_neighbors</code> $\in \{3, 5, 7, 11, 15\}$; <code>metric</code> $\in \{\text{euclidean}, \text{manhattan}\}$
Naive Bayes	<code>var_smoothing</code>	$\{10^{-9}, 10^{-7}, 10^{-5}\}$
Random Forest	<code>n_estimators</code> ; <code>max_depth</code>	<code>n_estimators</code> $\in \{100, 200, 500\}$; <code>max_depth</code> $\in \{\text{None}, 10, 20\}$
XGBoost	<code>n_estimators</code> ; <code>learning_rate</code> ; <code>max_depth</code>	<code>n_estimators</code> $\in \{100, 200\}$; <code>lr</code> $\in \{0.01, 0.1\}$; <code>max_depth</code> $\in \{3, 6\}$
MLP	<code>hidden_layer_sizes</code> ; <code>learning_rate_init</code>	<code>sizes</code> $\in \{(64,), (128,), (64, 64)\}$; <code>lr</code> $\in \{0.001, 0.01\}$

Kết quả cuối cùng được báo cáo trên tập test với bộ siêu tham số tốt nhất tìm được. Để đảm bảo tính tái tạo (*reproducibility*), `random_state` được cố định ở giá trị 42 cho tất cả các bước có yếu tố ngẫu nhiên.

3.1.3. Các độ đo đánh giá

Bộ độ đo được lựa chọn khác nhau giữa hai pipeline phản ánh đặc thù của từng bài toán:

- **Pipeline Breast Cancer** (phân loại đa lớp, dữ liệu tương đối cân bằng): báo cáo Accuracy, Precision (macro), Recall (macro), F1-score (macro) và ROC-AUC (macro, one-vs-rest). F1-score macro được chọn là độ đo so sánh chính vì nó đánh giá đồng đều trên tất cả 6 lớp ung thư vú mà không ưu tiên lớp nào.
- **Pipeline Diabetes** (phân loại đa lớp với mất cân bằng lớp): ưu tiên F1-score (macro) và ROC-AUC làm độ đo chính. Accuracy được ghi nhận nhưng không dùng để so sánh mô hình do bị thiên lệch bởi lớp đa số. Confusion Matrix được phân tích chi tiết để quan sát mức độ thiên lệch về phía lớp đa số trước và sau khi resampling.

Đối với bài toán phân loại đa lớp, ROC-AUC được tính theo phương pháp one-vs-rest (OvR): với mỗi lớp k , tính AUC của bài toán nhị phân “lớp k so với tất cả các lớp còn lại”, sau đó lấy trung bình macro.

3.2 Mô tả bộ dữ liệu

3.2.1. Bộ dữ liệu Breast Cancer Gene Expression (GSE45827 — CuMiDa)

Bộ dữ liệu GSE45827 được lấy từ kho lưu trữ GEO (*Gene Expression Omnibus*) và phiên bản đã qua tiền xử lý từ CuMiDa (*Curated Microarray Database*). Dữ liệu biểu hiện gene của các mẫu mô ung thư vú được đo bằng công nghệ microarray, trong đó mỗi mẫu tương ứng với một bệnh nhân và mỗi đặc trưng là mức độ biểu hiện của một gene cụ thể.

- **Số mẫu:** 151 mẫu (bệnh nhân).
- **Số đặc trưng:** 54.676 gene — tạo ra tỉ lệ đặc trưng/mẫu xấp xỉ 362:1, điển hình cho vấn đề số chiều cao nghiêm trọng trong dữ liệu omics.
- **Biến mục tiêu:** 6 lớp phân loại — Triple Negative Breast Cancer (TNBC), HER2-enriched, Luminal A, Luminal B, Luminal C và mô vú bình thường (Normal).
- **Vấn đề chủ đạo:** Số chiều cực cao dẫn đến nguy cơ overfitting và *curse of dimensionality*; tính phi tuyến trong không gian biểu hiện gene.

Dữ liệu trong CuMiDa đã qua bước chuẩn hóa RMA (*Robust Multi-array Average*) và $\log_2$ -transform tiêu chuẩn, do đó giá trị biểu hiện gene không chứa giá trị âm và đã ở thang đo logarithm — phù hợp cho việc áp dụng trực tiếp `StandardScaler` mà không cần biến đổi thêm.

3.2.2. Bộ dữ liệu Diabetes Health Indicators (BRFSS 2015 — CDC)

Bộ dữ liệu được xây dựng từ cuộc khảo sát *Behavioral Risk Factor Surveillance System* (BRFSS) năm 2015 của Trung tâm Kiểm soát và Phòng ngừa Dịch bệnh Hoa Kỳ (CDC).

Đây là cuộc khảo sát sức khỏe cộng đồng thường niên thu thập thông tin về hành vi sức khỏe, điều kiện mãn tính và dịch vụ y tế dự phòng từ dân số Hoa Kỳ.

- **Số mẫu:** 253.680 mẫu (người được khảo sát).
- **Số đặc trưng:** 21 đặc trưng gồm các chỉ số sức khỏe (BMI, huyết áp, cholesterol), hành vi lối sống (hút thuốc, uống rượu, hoạt động thể chất), và đặc điểm nhân khẩu học (tuổi, giới tính, trình độ học vấn, thu nhập).
- **Biến mục tiêu:** 3 lớp — không mắc tiểu đường (0), tiền tiểu đường (1) và tiểu đường (2). Phân phối lớp: lớp 0 chiếm ~84%, lớp 1 và 2 chiếm ~16% — mất cân bằng lớp rõ rệt với tỉ lệ xấp xỉ 5:1.
- **Vấn đề chủ đạo:** Mất cân bằng lớp nghiêm trọng và tính phi tuyến trong mối quan hệ giữa các chỉ số sức khỏe và nguy cơ tiểu đường.

3.3 Pipeline Breast Cancer — Xử lý số chiều cao và phân tích phi tuyến

Pipeline này được thiết kế để giải quyết thách thức chính của bộ dữ liệu GSE45827: không gian đặc trưng 54.676 chiều với chỉ 151 mẫu. Sơ đồ tổng quan các bước xử lý được trình bày trong Bảng 3.2.

3.3.1. Tiền xử lý dữ liệu

Bước tiền xử lý cho bộ dữ liệu GSE45827 bao gồm các thao tác sau được thực hiện theo thứ tự:

Kiểm tra và xử lý giá trị bị thiếu. Mặc dù dữ liệu CuMiDa đã qua tiền xử lý chuẩn hóa, việc kiểm tra giá trị bị thiếu vẫn được thực hiện như bước bắt buộc. Với mỗi gene (cột), tính tỉ lệ giá trị bị thiếu; các gene có tỉ lệ thiếu vượt quá 20% sẽ bị loại bỏ; các gene còn lại nếu có giá trị thiếu sẽ được điền thế bằng giá trị trung bình của gene đó trên tập train.

Mã hóa nhãn. Nhãn lớp ở dạng chuỗi (“TNBC”, “HER2”, “LumA”, “LumB”, “LumC”, “Normal”) được chuyển đổi thành số nguyên bằng `LabelEncoder` của `scikit-learn`. Ảnh xạ mã hóa được lưu lại để khôi phục tên lớp khi trình bày kết quả.

Chuẩn hóa đặc trưng. `StandardScaler` (chuẩn hóa z-score) được fit trên tập train và transform lên cả train và test:

$$x'_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j} \quad (3.1)$$

Bảng 3.2: Sơ đồ tổng quan Pipeline Breast Cancer.

Bước	Tên bước	Mô tả chi tiết
1	Mô tả & thống kê	Thống kê số mẫu, số đặc trưng, phân bố nhãn lớp, kiểm tra giá trị bị thiếu và phân phối biểu hiện gene.
2	Tiền xử lý	Xử lý giá trị bị thiếu, chuẩn hóa StandardScaler , mã hóa nhãn (<i>Label Encoding</i>).
3	Trực quan hóa (t-SNE, UMAP)	Chiếu dữ liệu đã chuẩn hóa xuống không gian 2D để quan sát khả năng phân tách giữa các lớp và xác nhận tính phi tuyến. Không dùng để huấn luyện mô hình.
4	Feature Selection	Filter: Variance Threshold $\rightarrow$ SelectKBest (ANOVA F-test). Wrapper: RFECV với Random Forest làm base estimator. Tất cả fit chỉ trên tập train.
5	Phân loại	Huấn luyện 8 mô hình $\times$ 3 phiên bản dữ liệu (gốc / filter / wrapper). Tối ưu siêu tham số bằng GridSearchCV + Stratified K-Fold.
6	Đánh giá & phân tích	So sánh Accuracy, F1-score (macro), ROC-AUC. Phân tích feature importance để xét vai trò phi tuyến của các gene được chọn.

trong đó μ_j và σ_j lần lượt là trung bình và độ lệch chuẩn của gene j tính trên tập train. Chuẩn hóa này bắt buộc cho SVM và MLP, đồng thời cải thiện độ ổn định số học cho ANOVA F-test trong bước SelectKBest tiếp theo.

3.3.2. Trực quan hóa và xác nhận tính phi tuyến

Với 54.676 chiều, việc quan sát trực tiếp cấu trúc dữ liệu là không khả thi. Hai kỹ thuật phi tuyến được sử dụng để chiếu dữ liệu xuống không gian 2D nhằm phân tích cấu trúc phân tách giữa các lớp ung thư.

t-SNE (*t-Distributed Stochastic Neighbor Embedding*). t-SNE được áp dụng trên toàn bộ dữ liệu đã chuẩn hóa ($151 \text{ mẫu} \times 54.676 \text{ đặc trưng}$) với tham số `perplexity` = 30. Thuật toán mô hình hóa xác suất tương đồng giữa các cặp điểm trong không gian gốc theo phân phối Gaussian:

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)} \quad (3.2)$$

và trong không gian 2D theo phân phối t-Student bậc 1 (để giải quyết vấn đề *crowding*):

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}} \quad (3.3)$$

Hàm mục tiêu tối thiểu hóa KL-divergence giữa hai phân phối này:

$$\mathcal{L}_{\text{t-SNE}} = \text{KL}(P||Q) = \sum_i \sum_j p_{ij} \log \frac{p_{ij}}{q_{ij}} \quad (3.4)$$

Kết quả t-SNE được tô màu theo nhãn lớp thực; nếu các lớp tạo thành các cụm tách biệt trong không gian 2D phi tuyến, điều đó xác nhận dữ liệu có cấu trúc phi tuyến có thể khai thác được.

UMAP (*Uniform Manifold Approximation and Projection*). UMAP được áp dụng bổ sung với `n_neighbors` = 15 và `min_dist` = 0.1 — các giá trị mặc định phù hợp cho khám phá cấu trúc tổng quát. Khác với t-SNE chỉ bảo toàn cấu trúc cục bộ, UMAP dựa trên lý thuyết topology và đồ thị k -nearest neighbors có trọng số để bảo toàn cả cấu trúc cục bộ lẫn cấu trúc toàn cục. Việc so sánh kết quả t-SNE và UMAP giúp đánh giá tính nhất quán của cấu trúc dữ liệu: nếu cả hai đều cho thấy phân tách lớp rõ ràng, cấu trúc phi tuyến được xem là bền vững và không phụ thuộc vào phương pháp chiếu cụ thể.

Feature importance sau phân loại. Sau khi huấn luyện các mô hình dựa trên cây (Random Forest, XGBoost, Decision Tree), feature importance score của từng gene được trích xuất và phân tích. Phân tích này hỗ trợ hai mục đích: (1) xác định các gene đóng vai trò phân biệt quan trọng nhất, và (2) đánh giá liệu các đặc trưng quan trọng có tập trung vào một nhóm chức năng sinh học nhất định không — phản ánh cấu trúc phi tuyến có tổ chức của không gian biểu hiện gene.

3.3.3. Lựa chọn đặc trưng (*Feature Selection*)

Với tỉ lệ đặc trưng/mẫu bằng 362:1, việc giảm số chiều là bắt buộc trước khi huấn luyện mô hình. Đề tài lựa chọn feature selection (giữ lại đặc trưng nguyên gốc) thay vì giảm chiều tuyến tính (PCA) vì: (1) feature selection bảo toàn khả năng giải thích sinh học của từng gene — quan trọng trong nghiên cứu ung thư; (2) PCA tạo ra các thành phần chính là tổ hợp tuyến tính của tất cả gene, khó giải thích ý nghĩa sinh học. Hai nhóm phương pháp được so sánh, tạo ra ba phiên bản dữ liệu:

Phiên bản gốc (Baseline). Toàn bộ 54.676 gene sau chuẩn hóa, không qua feature selection. Phiên bản này đóng vai trò baseline để định lượng tác động thực sự của feature selection lên hiệu năng phân loại. Do số chiều quá lớn, một số mô hình (đặc biệt KNN và SVM) có thể không hội tụ trong thời gian hợp lý — trường hợp này sẽ được ghi nhận.

Phiên bản Filter Selection. Pipeline filter gồm hai bước áp dụng tuần tự, chỉ fit trên tập train:

- **Variance Threshold:** loại bỏ các gene có phương sai $\text{Var}(x_j) < \theta$ trên tập train. Các gene có phương sai thấp gần như không thay đổi giữa các mẫu, do đó không mang thông tin phân biệt. Ngưỡng θ được đặt ở phân vị thứ 10 của phân phối phương sai — loại bỏ $\sim 10\%$ gene có độ biến động thấp nhất.
- **SelectKBest với ANOVA F-test:** trong số các gene còn lại sau Variance Threshold, chọn K gene có F-score cao nhất. F-test đánh giá mức độ khác biệt trung bình biểu hiện gene giữa các lớp ung thư so với phương sai nội nhóm:

$$F = \frac{\text{phương sai liên nhóm}}{\text{phương sai nội nhóm}} \quad (3.5)$$

Gene có F-score cao đồng nghĩa biểu hiện khác biệt rõ rệt giữa các phân nhóm ung thư. Giá trị K được tối ưu thông qua cross-validation trên tập train, thử nghiệm $K \in \{50, 100, 200, 500\}$.

Phiên bản Wrapper Selection (RFECV). *Recursive Feature Elimination with Cross-Validation* (RFECV) sử dụng Random Forest làm base estimator (`n_estimators` = 100, `random_state` = 42). Thuật toán hoạt động đệ quy theo các bước: (1) Huấn luyện Random Forest trên toàn bộ đặc trưng hiện tại; (2) Tính feature importance score cho từng gene; (3) Loại bỏ một tỉ lệ gene có importance thấp nhất (`step` = $0.1 \times$ số gene hiện tại); (4) Lặp lại cho đến khi đạt số gene tối thiểu; (5) Chọn số gene tối ưu dựa trên F1-score cross-validation.

Random Forest được chọn làm base estimator vì: nó cung cấp feature importance tự nhiên (Mean Decrease in Impurity), bền vững với overfitting, và chính là một trong các mô hình được đánh giá — đảm bảo tập gene chọn phù hợp với bài toán phân loại thực tế. Toàn bộ quá trình RFECV được fit chỉ trên tập train với Stratified K-Fold $k = 5$; số gene tối ưu được xác định tự động, không cần định nghĩa trước như SelectKBest.

3.3.4. Phân loại và đánh giá

Tám mô hình phân loại (Logistic Regression, SVM RBF, Decision Tree, KNN, Naive Bayes, Random Forest, XGBoost, MLP) được huấn luyện độc lập trên mỗi trong ba phiên bản dữ liệu (gốc / filter / wrapper), tạo ra tổng cộng 24 tổ hợp thực nghiệm. Mỗi tổ hợp trải qua GridSearchCV với Stratified K-Fold $k = 5$ để tìm siêu tham số tối ưu, sau đó đánh giá trên tập test giữ nguyên.

Các câu hỏi nghiên cứu được trả lời thông qua so sánh:

- Feature selection có cải thiện hiệu năng so với dữ liệu gốc không, và cải thiện ở mức độ nào?
- Filter selection và Wrapper selection cho kết quả khác nhau như thế nào về số lượng gene được chọn, mức độ trùng lặp giữa hai tập gene và hiệu năng phân loại?
- Logistic Regression có kém hơn đáng kể so với các mô hình phi tuyến (SVM RBF, Random Forest, XGBoost, MLP) không — qua đó định lượng mức độ phi tuyến thực sự của dữ liệu?

3.4 Pipeline Diabetes — Xử lý mất cân bằng lớp và phân tích phi tuyến

Pipeline này được thiết kế để giải quyết thách thức chính của bộ dữ liệu BRFSS 2015: mất cân bằng lớp với tỉ lệ xấp xỉ 5:1 giữa nhóm không bệnh và nhóm tiền tiểu đường/tiểu đường. Sơ đồ tổng quan được trình bày trong Bảng 3.3.

3.4.1. Tiền xử lý dữ liệu

Kiểm tra giá trị bất thường. Các đặc trưng lâm sàng được kiểm tra đối chiếu với phạm vi sinh lý hợp lý. Ví dụ: chỉ số BMI = 0 là không hợp lệ về mặt y học; tương tự với huyết áp tâm thu = 0. Các giá trị bất thường được xử lý bằng imputation theo trung vị của lớp tương ứng (*class-conditional median imputation*) để giữ thông tin nhân lớp trong quá trình điền thế, thay vì imputation toàn cục có thể làm nhiễu phân phối của lớp thiểu số.

Chuẩn hóa đặc trưng. StandardScaler được fit trên tập train và transform lên cả train và test, tương tự Pipeline Breast Cancer. Với bộ dữ liệu Diabetes, các đặc trưng có thang đo rất khác nhau ($BMI \in [12, 98]$, $Age \in [1, 13]$ theo nhóm tuổi, $Income \in [1, 8]$ theo nhóm thu nhập) — chuẩn hóa đảm bảo khoảng cách Euclidean trong KNN và kernel RBF trong SVM không bị chi phối bởi các đặc trưng có thang đo lớn hơn.

Bảng 3.3: Sơ đồ tổng quan Pipeline Diabetes.

Bước	Tên bước	Mô tả chi tiết
1	Mô tả & thống kê	Thống kê số mẫu, số đặc trưng, tỉ lệ mất cân bằng lớp (đa số:thiểu số), phân bố từng chỉ số sức khỏe.
2	Tiền xử lý	Kiểm tra giá trị bất thường (ngoài phạm vi sinh lý), chuẩn hóa <code>StandardScaler</code> .
3	Trực quan hóa (t-SNE, UMAP)	Quan sát mức độ chồng lấp giữa các lớp và xác nhận tính phi tuyến trong dữ liệu lâm sàng.
4	Resampling (chỉ trên train)	Ba phiên bản tập train: Baseline (không resampling), SMOTE, SMOTE+ENN. Tập test giữ nguyên phân phối gốc.
5	Phân loại	Huấn luyện 8 mô hình $\times$ 3 phiên bản dữ liệu. Tối ưu siêu tham số bằng GridSearchCV + Stratified K-Fold.
6	Đánh giá & phân tích	So sánh F1-score (macro), ROC-AUC, Confusion Matrix. Accuracy ghi nhận nhưng không phải độ đo chính.

3.4.2. Trực quan hóa và xác nhận tính phi tuyến

Do kích thước lớn của bộ dữ liệu (253.680 mẫu), t-SNE và UMAP được áp dụng trên một tập con đại diện (*stratified sample*) gồm 5.000 mẫu — đảm bảo tỉ lệ các lớp trong tập con phản ánh đúng phân phối gốc. Việc áp dụng t-SNE/UMAP trên toàn bộ 253.680 mẫu sẽ tốn thời gian tính toán quá lớn (t-SNE có độ phức tạp $\mathcal{O}(n^2)$) mà không mang lại thêm thông tin đáng kể so với tập con đại diện.

Trên dữ liệu lâm sàng, kỳ vọng là các lớp chồng lấp nhiều hơn so với dữ liệu gene expression — do ranh giới giữa “không bệnh”, “tiền tiểu đường” và “tiểu đường” không rõ ràng trong không gian đặc trưng lâm sàng. Mức độ chồng lấp quan sát được qua t-SNE/UMAP sẽ giải thích tại sao bài toán phân loại Diabetes khó hơn và tại sao các kỹ thuật resampling cần thiết.

Feature importance của Random Forest và XGBoost được so sánh với hệ số hồi quy của Logistic Regression: nếu thứ tự quan trọng của các đặc trưng khác nhau đáng kể giữa hai nhóm mô hình, có thể kết luận rằng mô hình phi tuyến đang nắm bắt các tương tác đặc trưng mà mô hình tuyến tính bỏ qua.

3.4.3. Xử lý mất cân bằng dữ liệu

Mất cân bằng lớp được xử lý theo phương pháp resampling — chỉ áp dụng trên tập train sau khi đã phân chia train/test. Quyết định không áp dụng resampling trên tập test là bắt buộc: tập test phải giữ nguyên phân phối tự nhiên của dữ liệu để đánh giá hiệu năng mô hình phản ánh đúng kịch bản triển khai thực tế, trong đó dữ liệu mới cũng có phân

phối tự nhiên mất cân bằng. Ba phiên bản tập train được chuẩn bị:

Phiên bản Baseline (không resampling). Tập train giữ nguyên phân phối gốc mất cân bằng. Phiên bản này cho phép quan sát hệ quả trực tiếp của mất cân bằng lên hành vi mô hình: kỳ vọng Accuracy cao nhưng F1-score và Recall trên lớp thiểu số thấp — mô hình thiên vị về phía lớp “không bệnh” do lớp này chiếm đa số.

Phiên bản SMOTE. SMOTE (*Synthetic Minority Over-sampling Technique*) tạo mẫu tổng hợp cho lớp thiểu số bằng cách nội suy tuyến tính trong không gian đặc trưng. Với mỗi mẫu x_i thuộc lớp thiểu số, thuật toán chọn ngẫu nhiên một trong $k = 5$ láng giềng gần nhất x_{nn} cùng lớp và tạo mẫu mới:

$$x_{\text{new}} = x_i + \lambda \cdot (x_{nn} - x_i), \quad \lambda \sim \mathcal{U}[0, 1] \quad (3.6)$$

Quá trình này được lặp lại cho đến khi tỉ lệ lớp thiểu số đạt mức mong muốn (thường là 1:1 hoặc tỉ lệ được chỉ định qua tham số `sampling_strategy`). Mục tiêu: cải thiện Recall trên lớp thiểu số bằng cách cung cấp nhiều ví dụ huấn luyện hơn.

Phiên bản SMOTE+ENN. SMOTE+ENN kết hợp bước tạo mẫu của SMOTE với bước làm sạch của *Edited Nearest Neighbors* (ENN). Sau khi SMOTE tạo mẫu tổng hợp, ENN kiểm tra từng mẫu (của cả hai lớp) và loại bỏ mẫu nếu nhãn của nó khác với nhãn đa số trong $k = 3$ láng giềng gần nhất:

$$\text{Loại bỏ } x_i \text{ nếu } \underset{k}{\operatorname{argmax}} \# \{x_j \in \mathcal{N}_k(x_i) : y_j = k\} \neq y_i \quad (3.7)$$

Bước ENN này làm sạch vùng biên giữa các lớp bằng cách loại bỏ các điểm nhiễu và các điểm nằm sâu trong vùng chồng lấp — cả từ lớp thiểu số lẫn lớp đa số. Kỳ vọng: biên quyết định sau SMOTE+ENN sạch hơn, dẫn đến Precision cải thiện mà không giảm đáng kể Recall so với SMOTE thuần túy. Tuy nhiên, số mẫu sau SMOTE+ENN thường ít hơn sau SMOTE do bước loại bỏ ENN.

3.4.4. Phân loại và đánh giá

Tám mô hình được huấn luyện trên ba phiên bản tập train (Baseline / SMOTE / SMOTE+ENN), tạo ra tổng cộng 24 tổ hợp thực nghiệm. Tập test giữ nguyên trong cả 24 tổ hợp để đảm bảo tính so sánh được. Siêu tham số tối ưu được tìm bằng GridSearchCV với tiêu chí F1-score macro.

Các câu hỏi nghiên cứu được trả lời:

- SMOTE và SMOTE+ENN cải thiện F1-score và ROC-AUC trên lớp thiểu số (tiền tiểu đường và tiểu đường) ở mức độ nào so với Baseline?
- SMOTE+ENN có nhất quán cho kết quả tốt hơn SMOTE trên tất cả tám mô hình không, hay ưu thế của SMOTE+ENN phụ thuộc vào loại mô hình?

- Mô hình phi tuyến có vượt trội Logistic Regression một cách nhất quán không — qua đó xác nhận tính phi tuyến trong dữ liệu lâm sàng?
- Mô hình nào đạt sự cân bằng tốt nhất giữa Precision và Recall trên lớp thiểu số (F1-score cao), thể hiện qua Confusion Matrix?

3.5 Tổng kết chương

Chương này đã trình bày đầy đủ quy trình thực nghiệm gồm hai pipeline độc lập, được thiết kế phù hợp với đặc thù của từng bộ dữ liệu. Các điểm chính cần nhấn mạnh:

- Nguyên tắc *no data leakage* được tuân thủ nghiêm ngặt xuyên suốt: mọi fit đều trên tập train, mọi transform lên tập test đều dùng tham số từ tập train.
- Ba phiên bản dữ liệu trong mỗi pipeline (gốc / xử lý 1 / xử lý 2) cho phép định lượng tác động độc lập của từng kỹ thuật xử lý lên hiệu năng mô hình.
- Tám mô hình phân loại đại diện cho toàn bộ phổ từ tuyến tính (Logistic Regression) đến phi tuyến phức tạp (MLP, XGBoost), cho phép phân tích tương quan giữa mức độ phi tuyến của dữ liệu và hiệu năng của từng nhóm mô hình.
- Trực quan hóa t-SNE và UMAP đóng vai trò phân tích định tính bổ trợ cho kết quả định lượng, giúp giải thích tại sao một số mô hình hoạt động tốt hơn trên từng bộ dữ liệu.

Kết quả thực nghiệm từ 48 tổ hợp (24 cho mỗi pipeline) sẽ được trình bày và phân tích chi tiết trong Chương 4.

Tài liệu tham khảo