

Tên đề tài:

Predictive Models for Healthcare Data

(Mô hình dự đoán trong dữ liệu chăm sóc sức khỏe)

CHƯƠNG 1. GIỚI THIỆU:

Chương này trình bày bối cảnh nghiên cứu, lý do chọn đề tài, các mục tiêu cần đạt được cũng như phạm vi và nội dung thực hiện của khóa luận. Từ thực trạng dữ liệu y tế ngày càng phức tạp với các đặc tính phi tuyến và mất cân bằng lớp, đề tài đặt ra vấn đề cần khảo sát hiệu quả của các mô hình học máy trong bài toán dự đoán trên dữ liệu chăm sóc sức khỏe.

1.1. Lý do chọn đề tài

Trong những năm gần đây, dữ liệu y tế ngày càng gia tăng cả về quy mô và độ phức tạp. Các kỹ thuật Machine Learning đang được ứng dụng rộng rãi trong lĩnh vực healthcare nhằm hỗ trợ chẩn đoán bệnh, hỗ trợ bác sĩ trong việc ra quyết định và phát hiện sớm nguy cơ bệnh lý.

Tuy nhiên, dữ liệu y tế thường tồn tại nhiều đặc điểm phức tạp như tính phi tuyến, dữ liệu số chiều cao, mất cân bằng lớp và nhiễu dữ liệu. Những đặc tính này gây khó khăn cho quá trình xây dựng và đánh giá các mô hình dự đoán.

Vì vậy, đề tài được thực hiện nhằm khảo sát hiệu quả của các mô hình học máy trên các bộ dữ liệu healthcare có đặc tính phi tuyến và mất cân bằng dữ liệu, từ đó đánh giá khả năng ứng dụng của các mô hình trong bài toán dự đoán y tế.

1.2. Mục tiêu nghiên cứu

Đề tài hướng đến các mục tiêu sau:

- Khảo sát hiệu quả của các mô hình học máy trên dữ liệu y tế.
- Phân tích ảnh hưởng của tính phi tuyến và mất cân bằng dữ liệu đến kết quả dự đoán.
- So sánh hiệu năng của các mô hình:
 - Logistic Regression
 - SVM với kernel RBF
 - Random Forest
 - XGBoost
 - Multi-layer Perceptron (MLP)

1.3. Đối tượng nghiên cứu

Đề tài sử dụng hai bộ dữ liệu:

- Breast Cancer Gene Expression Dataset
- Diabetes Dataset

1.4. Phạm vi nghiên cứu

- Chỉ sử dụng các phương pháp supervised learning.
- Không nghiên cứu chuyên sâu về Deep Learning.
- Không triển khai hệ thống thực tế trong môi trường bệnh viện.

1.5. Nội dung thực hiện

- Tiền xử lý dữ liệu.
- Trực quan hóa dữ liệu.
- Phân cụm dữ liệu.
- Classification.
- Xử lý mất cân bằng dữ liệu.
- Đánh giá và so sánh mô hình.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT:

Chương này trình bày các kiến thức nền tảng phục vụ cho quá trình thực nghiệm. Trước tiên, tổng quan về ứng dụng Machine Learning trong healthcare được giới thiệu nhằm đặt đề tài vào bối cảnh nghiên cứu hiện tại. Tiếp theo, các đặc tính thường gặp của dữ liệu y tế được phân tích để lý giải cho việc lựa chọn phương pháp nghiên cứu. Sau đó, các nhóm kỹ thuật được trình bày theo đúng thứ tự pipeline thực nghiệm: giảm chiều và trực quan hóa, phân cụm, classification, xử lý mất cân bằng dữ liệu, và cuối cùng là các độ đo đánh giá.

2.1. Tổng quan về Machine Learning trong healthcare:

Mục này giới thiệu bức tranh tổng quan về việc ứng dụng trí tuệ nhân tạo trong lĩnh vực y tế, đặc biệt là predictive analytics - nền tảng lý thuyết mà đề tài hướng đến.

- Ứng dụng AI trong lĩnh vực y tế.
- Predictive analytics trong healthcare.

2.2. Các đặc tính của dữ liệu y tế

- High-dimensional data.
- Nonlinear patterns.
- Imbalanced data.
- Noise and outliers.

-> Dữ liệu y tế thường mang những đặc tính riêng biệt gây khó khăn cho quá trình mô hình hóa. Mục này phân tích bốn đặc tính chính: số chiều cao, tính phi tuyến, mất cân bằng lớp và nhiễu dữ liệu. Việc hiểu rõ các đặc tính này là cơ sở để lựa chọn phương pháp xử lý phù hợp ở chương 3.

2.3. Các kỹ thuật giảm chiều và trực quan hóa dữ liệu

PCA:

- Nguyên lý hoạt động.
- Ưu điểm và hạn chế.

t-SNE:

- Ý tưởng neighborhood và bảo toàn khoảng cách cục bộ.

UMAP:

- Topological structure.
- So sánh với t-SNE.

-> Với dữ liệu có số chiều cao, việc trực quan hóa trực tiếp là không khả thi. Mục này trình bày ba kỹ thuật giảm chiều được sử dụng trong đề tài: PCA giữ lại phương sai toàn cục, t-SNE bảo toàn cấu trúc cục bộ, và UMAP kết hợp cả hai ưu điểm trên. Ba kỹ thuật này sẽ được áp dụng trong pipeline Breast Cancer để khảo sát cấu trúc phi tuyến của dữ liệu.

[Xem xét lại] 2.4. Các thuật toán phân cụm

- KMeans.
- DBSCAN.
- Gaussian Mixture Model (GMM).
- Hierarchical Clustering.

2.5. Các mô hình classification: 5 mô hình chính của đề tài

- Logistic Regression.
- SVM với kernel RBF.
- Random Forest.
- XGBoost.
- Multi-layer Perceptron (MLP).

2.6. Xử lý mất cân bằng dữ liệu

- SMOTE (Synthetic Minority Oversampling Technique)
- ADASYN (Adaptive Synthetic Sampling)
- ROS (Random Over Sampling)
- RUS (Random Under Sampling)
- Tomek Links
- SMOTE + ENN (SMOTE kết hợp Edited Nearest Neighbors)

-> Mất cân bằng lớp là vấn đề phổ biến trong dữ liệu y tế, khi số lượng mẫu bệnh thường ít hơn nhiều so với mẫu bình thường. Mục này trình bày các kỹ thuật resampling sẽ được khảo sát trên bộ dữ liệu Diabetes, bao gồm cả oversampling, undersampling và phương pháp kết hợp.

2.7. Các độ đo đánh giá

- Accuracy.
- Precision.
- Recall.
- F1-score.
- ROC-AUC.
- Silhouette Score.
- Davies-Bouldin Index.

-> Mục này trình bày các độ đo được sử dụng xuyên suốt quá trình thực nghiệm. Đối với classification, các độ đo Accuracy, Precision, Recall, F1-score và ROC-AUC được sử dụng, trong đó F1-score và ROC-AUC được ưu tiên khi dữ liệu mất cân bằng. Đối với clustering, Silhouette Score và Davies-Bouldin Index được dùng để đánh giá chất lượng phân cụm.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU: Chương này trình bày chi tiết quy trình thực nghiệm cho từng bộ dữ liệu. Hai pipeline được thiết kế riêng biệt nhằm giải quyết hai vấn đề khác nhau của dữ liệu y tế: pipeline Breast Cancer tập trung vào khảo sát cấu trúc phi tuyến và so sánh mô hình trên dữ liệu số chiều cao, trong khi pipeline Diabetes tập trung vào ảnh hưởng của kỹ thuật xử lý mất cân bằng đến hiệu năng mô hình.

3.1. Quy trình thực nghiệm tổng quát

Pipeline thực nghiệm bao gồm các bước:

- Load dữ liệu.
- Tiền xử lý dữ liệu.
- Trực quan hóa và phân tích cấu trúc dữ liệu.
- Giảm chiều dữ liệu (đối với bộ Breast Cancer).
- Xử lý mất cân bằng dữ liệu (đối với bộ Diabetes).
- Classification.
- Evaluation.

3.1.1. Thiết lập thực nghiệm

Dữ liệu được chia theo tỉ lệ 80% huấn luyện và 20% kiểm tra (train/test split) với stratified sampling nhằm đảm bảo tỉ lệ các lớp được giữ nguyên ở cả tập train và test. Đối với bộ dữ liệu Diabetes có hiện tượng mất cân bằng lớp, các kỹ thuật resampling chỉ được áp dụng trên tập huấn luyện để tránh data leakage.

Phương pháp Stratified K-Fold Cross-Validation với $k = 5$ được sử dụng trên tập huấn luyện nhằm đánh giá hiệu năng mô hình một cách ổn định và giảm thiểu ảnh hưởng của phương sai do phân chia dữ liệu. Kết quả cuối cùng được báo cáo trên tập test để đánh giá khả năng tổng quát hóa của mô hình.

Grid Search kết hợp với Cross-Validation (GridSearchCV) được sử dụng để tìm bộ siêu tham số tối ưu cho từng mô hình. Các siêu tham số được khảo sát bao gồm: C và γ cho SVM RBF, số cây ($n_estimators$) và độ sâu tối đa (max_depth) cho Random Forest và XGBoost, số neuron và learning rate cho MLP. Chi tiết không gian tìm kiếm được trình bày trong phụ lục.

Toàn bộ thực nghiệm được thực hiện bằng ngôn ngữ Python với các thư viện chính: scikit-learn, XGBoost, imbalanced-learn, matplotlib và seaborn.

3.2. Bộ dữ liệu Breast Cancer ([GEO Accession viewer](#) hoặc [Breast cancer gene expression - CuMiDa](#))

3.2.1. Mô tả dữ liệu

- Dữ liệu gene expression.
- Dữ liệu có số chiều cao.
- Bao gồm các lớp bệnh khác nhau.

3.2.2. Tiền xử lý dữ liệu

- Xử lý missing values.
- Scaling dữ liệu.
- Encoding nhãn.

3.2.3. Phân tích cấu trúc dữ liệu

Các kỹ thuật được sử dụng:

- PCA.
- t-SNE.
- UMAP.

Mục tiêu:

- Khảo sát cấu trúc dữ liệu.
- Quan sát xu hướng phân tách phi tuyến giữa các lớp dữ liệu.

(Dữ liệu gene expression thường có số chiều rất cao và tồn tại các mối quan hệ phi tuyến phức tạp giữa các đặc trưng. Do đó, việc trực quan hóa dữ liệu là cần thiết để khảo sát cấu trúc phân bố của dữ liệu, quan sát khả năng phân tách giữa các lớp và đánh giá xu hướng phi tuyến trong không gian đặc trưng. Các kỹ thuật PCA, t-SNE và UMAP được sử dụng nhằm hỗ trợ phân tích trực quan và khám phá cấu trúc tiềm ẩn của dữ liệu.)

[Xem xét lại] 3.2.4. Phân cụm dữ liệu

Các thuật toán clustering:

- KMeans.
- DBSCAN.
- Gaussian Mixture Model.
- Hierarchical Clustering.

Đánh giá:

- Silhouette Score.
- Visualization kết quả phân cụm.

Clustering chỉ để trực quan hóa và kiểm tra xem dữ liệu có tách cụm rõ ràng không trước khi train classification. Nếu KMeans/DBSCAN tách được gần đúng nhãn thật → dữ liệu có cấu trúc tốt → classification sẽ hiệu quả. Viết đúng bản chất, không phóng đại.

3.2.5. Classification

So sánh các mô hình:

- Logistic Regression.
- SVM RBF.
- Random Forest.
- XGBoost.
- MLP.

3.3. Bộ dữ liệu Diabetes ([Diabetes Health Indicators Dataset](#))

3.3.1. Mô tả dữ liệu

- Dữ liệu có hiện tượng mất cân bằng lớp.

3.3.2. Tiền xử lý dữ liệu

- Scaling dữ liệu.
- Cleaning dữ liệu.

3.3.3. Xử lý mất cân bằng dữ liệu

Các kỹ thuật được sử dụng:

- SMOTE (Synthetic Minority Oversampling Technique)
- ADASYN (Adaptive Synthetic Sampling)
- ROS (Random Over Sampling)
- RUS (Random Under Sampling)

- Tomek Links
- SMOTE + ENN (SMOTE kết hợp Edited Nearest Neighbors)

Thực hiện so sánh hiệu quả giữa các phương pháp xử lý imbalance.

3.3.4. Classification

Huấn luyện các mô hình:

- Logistic Regression.
- SVM RBF.
- Random Forest.
- XGBoost.
- MLP.

3.3.5. Đánh giá mô hình

Các độ đo sử dụng:

- F1-score.
- ROC-AUC.
- Confusion Matrix.

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

4.1. Kết quả trên bộ dữ liệu Breast Cancer

4.1.1. Kết quả trực quan hóa dữ liệu

- Biểu đồ PCA, t-SNE, UMAP.
- Nhận xét mức độ phân tách giữa các lớp và xác nhận tính phi tuyến.

4.1.2. Kết quả classification

- So sánh 5 mô hình trên dữ liệu gốc vs PCA vs Kernel PCA.
- Bảng kết quả Accuracy, F1-score, ROC-AUC.
- Nhận xét: giảm chiều phi tuyến có cải thiện kết quả hay không.

4.2. Kết quả trên bộ dữ liệu Diabetes

4.2.1. Kết quả classification trên dữ liệu gốc

- Baseline: 5 mô hình trên dữ liệu chưa xử lý imbalance.

4.2.2. Ảnh hưởng của xử lý mất cân bằng dữ liệu

- So sánh kết quả: không sampling vs SMOTE vs SMOTE+ENN.
- Bảng kết quả F1-score, ROC-AUC, Confusion Matrix.

- Nhận xét: kỹ thuật resampling nào hiệu quả nhất.

4.3. So sánh tổng hợp và thảo luận

- So sánh cross-pipeline: mô hình nào ổn định trên cả hai bộ dữ liệu.
- Vai trò của ensemble models trong healthcare prediction.
- Tổng hợp các phát hiện chính.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN: *Chương cuối tổng kết lại các kết quả chính của khóa luận, chỉ ra những hạn chế còn tồn tại và đề xuất hướng phát triển trong tương lai. Các hướng mở rộng bao gồm ứng dụng Deep Learning, Explainable AI và Federated Learning — những xu hướng đang được quan tâm trong cộng đồng nghiên cứu y tế.*

5.1. Kết luận

- Tổng kết hiệu quả của các mô hình học máy.
- Nhận xét kết quả trên từng loại dữ liệu.

5.2. Hạn chế

- Dataset còn nhỏ.
- Chưa sử dụng Deep Learning chuyên sâu.
- Chưa tối ưu hyperparameter ở mức nâng cao.

5.3. Hướng phát triển

- Deep Learning cho dữ liệu y tế.
- Explainable AI như SHAP hoặc LIME.
- Multi-omics data.
- Federated Learning trong healthcare.

Đánh giá tổng thể

Đề tài tập trung nghiên cứu các mô hình dự đoán trên dữ liệu chăm sóc sức khỏe với hai đặc điểm phổ biến của dữ liệu y tế là tính phi tuyến và mất cân bằng lớp. Thông qua các kỹ thuật trực quan hóa, phân cụm, xử lý imbalance và classification, đề tài hướng đến việc đánh giá hiệu quả của nhiều mô hình Machine Learning trong các bài toán dự đoán y tế.

VẤN ĐỀ CẦN SỬA:

1. Phần thực hiện clustering có mục đích gì? Có thực sự hợp lý không? Khi UMAP, tSNE và PCA dùng để trực quan rồi.
2. Các kỹ thuật xử lý imbalanced data hơi nhiều, và việc quyết định giữ SMOTE và SMOTE+ENN bằng cách test hiệu suất trên Random Forest có hợp lý không? Có nên xóa đi bớt và chỉ dùng 2 kỹ thuật SMOTE và SMOTE+ENN để so sánh luôn thôi không?
3. PCA là giả định dữ liệu tuyến tính mà bộ Breast Cancer là phi tuyến nên cần thực hiện thêm Kernel PCA
4. Thực hiện training dữ liệu đã PCA, dữ liệu đã Kernel PCA và dữ liệu chưa PCA cho bộ dữ liệu Breast Cancer.